STUDI KOMPARATIF EFEK PARADIGMA PELATIHAN TERHADAP SKALABILITAS ARSITEKTUR MEDMAMBA UNTUK KLASIFIKASI CITRA PENYAKIT KULIT

TUGAS AKHIR

Muhammad Royhan Alfitra

123140146



PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
LAMPUNG SELATAN
2026

DAFTAR ISI

DAFTAR ISI ..... **ii**

DAFTAR TABEL ..... **v**

DAFTAR GAMBAR ..... **vi**

DAFTAR RUMUS ..... **vii**

DAFTAR KODE ..... **ix**

BAB I PENDAHULUAN **1**

1.1 Latar Belakang 1

1.2 Rumusan Masalah 3

1.3 Tujuan Penelitian 4

1.4 Batasan Masalah 5

1.5 Manfaat Penelitian 6

1.6 Sistematika Penulisan 6

BAB II TINJAUAN PUSTAKA **9**

2.1 Tinjauan Pustaka 9

2.2 Dasar Teori 15

2.2.1 DermaMNIST-C 15

2.2.1.1 Actinic Keratoses and Intraepithelial Carcinoma (`akiec`) 16

2.2.1.2 Basal Cell Carcinoma (`bcc`) 17

2.2.1.3 Benign Keratosis-Like Lesions (`bkl`) 18

2.2.1.4 Dermatofibroma (`df`) 18

2.2.1.5 Melanoma (`mel`) 19

2.2.1.6 Melanocytic Nevi (`nv`) 19

2.2.1.7 Vascular Lesions (`vasc`) 20

2.2.2 Ketidakseimbangan Data (*Imbalanced Data*) 21
2.2.3 Bias Induktif CNN dan Karakteristik Vision Transformer (ViT) 21
2.2.4 Arsitektur Residual Networks (ResNet) 22
2.2.5 Arsitektur State Space Models (SSM) dan MedMamba 24
2.2.5.1 State Space Models (SSM) 24
2.2.5.2 MedMamba 25
2.2.6 Paradigma Pelatihan: Supervised vs. Contrastive Learning 26
2.2.6.1 Paradigma Supervised Learning Langsung 26
2.2.6.2 Paradigma Supervised Contrastive Learning (SupCon) 26
2.2.7 Metrik Evaluasi, Kalibrasi, dan Efisiensi Komputasi 27
2.2.7.1 Metrik Kinerja Diagnostik Multikelas 27
2.2.7.2 Metrik Reliabilitas Kalibrasi Prediksi 28
2.2.7.3 Metrik Efisiensi Komputasi Hardware 29

BAB III METODE PENELITIAN 31
3.1 Alur Penelitian 31
3.2 Penjabaran Langkah Penelitian 32
3.2.1 Identifikasi Masalah 32
3.2.2 Studi Literatur 32
3.2.3 Akuisisi Dataset 32
3.2.4 Preprocessing Data 33
3.2.5 Augmentasi Data dan Penanganan Data Tak Seimbang 33
3.2.6 Perancangan Model dan Skenario Pelatihan 35
3.2.7 Evaluasi Model 35
3.3 Alat dan Bahan Tugas Akhir 36
3.3.1 Alat 36
3.3.2 Bahan Penelitian 36
3.3.3 Kelayakan Eksperimen dan Anggaran Komputasi 37

3.4 Metode Pengembangan 38
3.4.1 Spesifikasi Arsitektur Model MedMamba 38
3.4.2 Implementasi Paradigma Pelatihan 39
3.4.2.1 Supervised Learning 40
3.4.2.2 Supervised Contrastive Learning (SupCon) 40
3.5 Rancangan Pengujian dan Skema Eksperimen 41
3.5.1 Skenario 1: Evaluasi Skalabilitas MedMamba pada Paradigma Supervised Learning 41
3.5.2 Skenario 2: Evaluasi Skalabilitas MedMamba pada Paradigma Supervised Contrastive Learning 42
3.5.3 Skenario 3: Analisis Komparatif Efek Interaksi Paradigma dan Skalabilitas (Paradigma × Skala) 42
3.6 Metrik Evaluasi dan Protokol Validasi 43
3.6.1 Kriteria Pemilihan Model (Model Selection) dan Protokol Konvergensi 43
3.6.2 Metrik Performa Diagnostik Multikelas 44
3.6.3 Kuantifikasi Separabilitas Ruang Laten 45
3.6.4 Metrik Reliabilitas Kalibrasi Prediksi 45
3.6.5 Metrik Efisiensi Komputasi Hardware dan Protokol Profiling 46
3.6.6 Protokol Validasi Statistik dan Estimasi Ketidakpastian Uji 47

DAFTAR PUSTAKA **49**

LAMPIRAN **52**

A Karakteristik dan Partisi Dataset DermaMNIST-C 52
B Konfigurasi Detail Arsitektur MedMamba dan Keluarga ResNet 52
C Lingkungan Perangkat Lunak dan Reproduksibilitas Eksperimen 52

DAFTAR TABEL

Tabel 2.1 Matriks Pembanding Penelitian Terdahulu 12
Tabel 2.2 Distribusi Sampel per Kelas pada Partisi Baku DermaMNIST-C 16

DAFTAR GAMBAR

Gambar 2.1 Contoh Sampel Citra Dermatoskopi Kelas *Actinic Keratoses and Intraepithelial Carcinoma* (`akiec`) 17
Gambar 2.2 Contoh Sampel Citra Dermatoskopi Kelas *Basal Cell Carcinoma* (`bcc`) 17
Gambar 2.3 Contoh Sampel Citra Dermatoskopi Kelas *Benign Keratosis-Like Lesions* (`bkl`) 18
Gambar 2.4 Contoh Sampel Citra Dermatoskopi Kelas *Dermatofibroma* (`df`) 19
Gambar 2.5 Contoh Sampel Citra Dermatoskopi Kelas *Melanoma* (`mel`) 19
Gambar 2.6 Contoh Sampel Citra Dermatoskopi Kelas *Melanocytic Nevi* (`nv`) 20
Gambar 2.7 Contoh Sampel Citra Dermatoskopi Kelas *Vascular Lesions* (`vasc`) 20
Gambar 3.1 Alur Penelitian 31
Gambar 3.2 Arsitektur Model MedMamba [11] 38

DAFTAR RUMUS

Rumus 2.1	Fungsi Kerugian Class-Weighted Cross-Entropy	21
Rumus 2.2	Bobot Penalti Kelas Frekuensi Terbalik	21
Rumus 2.3	Pemetaan Residual Identitas ResNet	23
Rumus 2.4	Pemetaan Residual Proyeksi Linier ResNet	23
Rumus 2.5	Sistem Persamaan Keadaan Laten Kontinu SSM	24
Rumus 2.6	Diskretisasi State Space Model dengan Zero-Order Hold	25
Rumus 2.7	Mekanisme Seleksi Parameter Masukan Mamba S6	25
Rumus 2.8	Normalisasi Vektor Proyeksi Laten SupCon	27
Rumus 2.9	Fungsi Kerugian Supervised Contrastive (SupCon)	27
Rumus 2.10	Balanced Accuracy Multikelas	27
Rumus 2.11	Macro Precision Multikelas	27
Rumus 2.12	Macro F1-Score Multikelas	28
Rumus 2.13	Multiclass Matthews Correlation Coefficient	28
Rumus 2.14	Expected Calibration Error	28
Rumus 2.15	Brier Score Kalibrasi Probabilistik	29
Rumus 2.16	Akumulasi Jumlah Parameter Terbobot	29
Rumus 2.17	Normalisasi Satuan Komputasi GFLOPs	29
Rumus 2.18	Throughput Inferensi Perangkat Keras	29
Rumus 3.1	Pembobotan Penalti Kelas pada Pelatihan Mini-Batch	34
Rumus 3.2	Fungsi Kerugian SupCon Multi-View Tahap 1	40
Rumus 3.3	Perhitungan Macro F1-Score Evaluasi Uji	44
Rumus 3.4	Skor Silhouette Separabilitas Ruang Laten	45
Rumus 3.5	Expected Calibration Error Evaluasi Uji	45
Rumus 3.6	Brier Score Kalibrasi Probabilistik Uji	45
Rumus 3.7	Kalkulasi FLOPs Modul Cross-Scan 4-Arah VSSM	46

Rumus 3.8 Normalisasi Beban Komputasi GFLOPs Uji 46
Rumus 3.9 Dispersi Latensi Inferensi Interquartile Range 47
Rumus 3.10 Throughput Pemrosesan Citra Inferensi Uji 47
Rumus 3.11 Deviasi Standar Replikasi Multi-Seed 47
Rumus 3.12 Format Pelaporan Agregat Multi-Seed dan Bootstrap CI 48

DAFTAR KODE

BAB I
PENDAHULUAN

1.1 Latar Belakang

Penyakit kulit merupakan salah satu masalah kesehatan global yang paling umum dengan distribusi penyebaran yang cukup tinggi di berbagai belahan dunia [1]. Deteksi dini pada lesi kulit berpigmen, khususnya melanoma maligna, memiliki signifikansi prognosis yang sangat krusial di mana tingkat kelangsungan hidup pasien meningkat drastis apabila terdapat penanganan klinis yang dilakukan pada stadium awal [2]. Pemanfaatan teknologi *Deep Learning* berbasis pengolahan citra medis dermatoskopi telah terbukti mampu membantu praktisi medis dalam mengidentifikasi pola lesi secara objektif dan memperkecil risiko kesalahan manusia (*human error*) dalam proses diagnosis penyakit [3].

Namun demikian, implementasi praktis model *Deep Learning* pada domain dermatologi dihadapkan pada dua tantangan utama, yaitu ketimpangan distribusi kelas (*class imbalance*) yang ekstrem dan tingginya beban komputasi arsitektur jaringan saraf [4]. Pada dataset benchmark dermatoskopi populer seperti DermaMNIST, kelas mayoritas *Melanocytic Nevi* (`nv`) mendominasi hingga sekitar 67% dari keseluruhan data, sedangkan kelas penyakit langka dan kronis seperti *Dermatofibroma* (`df`) dan *Vascular Lesions* (`vasc`) yang masing-masing hanya mencakup kurang dari 1,5% populasi data [5]. Ketimpangan ekstrem ini menyebabkan fungsi objektif konvensional terbias ke arah kelas mayoritas, sehingga menghasilkan akurasi global yang tinggi semu namun memiliki sensitivitas (*recall*) yang sangat rendah pada kelas-kelas kritis [6], [7]. Di sisi lain, adopsi pada arsitektur *Vision Transformer* (ViT) [8] untuk menangkap konteks spasial global terhambat oleh kompleksitas komputasi kuadratik $O(N^2)$ terhadap panjangnya sekuens token atau resolusi citra, yang membebani memori VRAM dan memperlambat proses komputasi [9].

Sebagai terobosan terbaru dalam pemodelan sekuensial, arsitektur berbasis *State Space Models* (SSM) seperti Mamba [10] menawarkan kemampuan pemrosesan konteks global dengan kompleksitas linear $O(N)$ melalui mekanisme pemindaian selektif (*Selective Scan Mechanism*). Di ranah medis, Yue dan Li (2024) mengadaptasi paradigma tersebut menjadi sebuah arsitektur *MedMamba* [11], yang mengintegrasikan lapisan konvolusi untuk induksi fitur lokal dengan modul *Visual State Space Model* (VSSM) berbasis pemindaian silang 4-arah (*Cross-Scan Module*). MedMamba dirancang dalam beberapa varian skala parameter untuk klasifikasi multikelas medis, meliputi MedMamba-T (*Tiny*, $\sim$ 14,5M parameter), MedMamba-S (*Small*, $\sim$ 22,8M parameter), dan MedMamba-B (*Base*, $\sim$ 47,1M parameter). Variasi skala ini membuka peluang untuk mengeksplorasi secara empiris *trade-off* antara kapasitas representasi fitur, konsumsi memori VRAM, dan efisiensi waktu dalam komputasi [12].

Di samping aspek arsitektur, validitas ilmiah dari evaluasi model sangat bergantung pada kualitas data yang digunakan. Investigasi oleh Abhishek et al. (2025) mengungkap adanya temuan serius pada dataset DermaMNIST murni, di mana ditemukan kebocoran data (*data leakage*) sebesar **13,47‰** (1.006 dari 7.470 lesi unik) akibat pemisahan partisi latih, validasi, dan uji yang dilakukan di tingkat gambar (*image-level split*) alih-alih tingkat pasien atau lesi (*lesion-level split*) [5]. Kebocoran data ini menyebabkan skor evaluasi pada publikasi terdahulu terinflasi secara semu karena model menghafal fitur visual dari lesi pasien yang sama di partisi pengujian. Untuk mengembalikan integritas evaluasi ilmiah, maka penelitian akan menerapkan penggunaan dataset DermaMNIST versi terkoreksi, yaitu **DermaMNIST-C**, yang menerapkan pemisahan terisolasi di tingkat lesi (*lesion-level disjoint split*) beresolusi 224×224 piksel yang menjadi kebutuhan mutlak [5].

Tantangan selanjutnya terletak pada paradigma pelatihan model. Selama ini pelatihan model klasifikasi didominasi oleh *Supervised Learning* yang langsung menggunakan fungsi *Cross-Entropy* terbobot (*Class-Weighted Cross-*

Entropy). Pendekatan ini berfokus langsung pada pembentukan batas keputusan linier antar-kelas, namun rentan mengalami keruntuhan fitur (*representation collapse*) pada kelas minoritas. Sebagai alternatif, paradigma *Supervised Contrastive Learning* (SupCon) [13] memisahkan proses pembelajaran menjadi dua tahap: pembentukan manifold representasi fitur yang memaksimalkan kesamaan intra-kelas dan jarak inter-kelas di ruang laten menggunakan loss kontrastif, yang kemudian diikuti oleh pelatihan lapisan klasifikasi linier. Walau demikian, bagaimana efektivitas representasi SupCon berinteraksi dengan kapasitas skala arsitektur *State Space Models* (MedMamba) pada kondisi ketidakseimbangan kelas medis yang bersih dari kebocoran data belum pernah dikaji secara komprehensif.

Berdasarkan urgensi tersebut, penelitian ini dirancang untuk melakukan studi komparatif terstruktur mengenai efek paradigma pelatihan (*Supervised Learning* terbobot vs. *Supervised Contrastive Learning*) terhadap skalabilitas kapasitas parameter arsitektur MedMamba (Tiny, Small, dan Base) pada dataset dermatoskopi terkoreksi DermaMNIST-C, dengan menyertakan model konvensional ResNet-18 sebagai baseline pembanding. Skalabilitas dalam penelitian ini didefinisikan secara operasional sebagai pengaruh ekspansi kapasitas parameter model saat dilatih sepenuhnya dari awal (*from scratch / random initialization*) pada skenario data biomedis yang terbatas (8.215 citra latih).

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana efisiensi komputasi fisik (jumlah parameter, GFLOPs, latensi inferensi per sampel pada batch=1, dan konsumsi VRAM puncak) serta performa diagnostik klinis dari variasi skala arsitektur MedMamba (MedMamba-T, MedMamba-S, dan MedMamba-B) dibandingkan model

konvensional keluarga ResNet dengan parameter setara (ResNet-18, ResNet-50, dan ResNet-101) pada dataset DermaMNIST-C?

2. Sejauh mana perbandingan efektivitas paradigma pelatihan Supervised Learning terbobot (*Class-Weighted Cross-Entropy*) dan Supervised Contrastive Learning (SupCon) dalam mengekstrak representasi fitur lesi kulit yang diskriminatif serta menghasilkan reliabilitas kalibrasi probabilitas prediksi (*Expected Calibration Error* / ECE)?
3. Bagaimana interaksi antara variasi skala parameter arsitektur MedMamba dengan paradigma pelatihan yang diterapkan dalam mengatasi bias prediksi pada kelas-kelas penyakit kulit minoritas yang mengalami ketimpangan data ekstrem?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah ditetapkan, tujuan penelitian ini adalah sebagai berikut:

1. Mengimplementasikan dan mengevaluasi tiga skala arsitektur MedMamba (MedMamba-T, MedMamba-S, dan MedMamba-B) untuk mengidentifikasi *trade-off* empiris antara kapasitas representasi, jejak komputasi, dan akurasi diagnostik terhadap baseline konvensional keluarga ResNet dengan parameter setara (ResNet-18, ResNet-50, dan ResNet-101) pada dataset DermaMNIST-C.
2. Menganalisis secara komparatif pengaruh paradigma pelatihan berbasis *Class-Weighted Cross-Entropy* dan *Supervised Contrastive Learning* terhadap separabilitas ruang representasi laten dan tingkat kalibrasi kepercayaan prediksi model (ECE).
3. Menganalisis secara komparatif efek interaksi antara variasi skala parameter arsitektur MedMamba (MedMamba-T, MedMamba-S, MedMamba-B) dan paradigma pelatihan (Supervised Learning vs. SupCon) dalam mengatasi bias prediksi pada kelas-kelas minoritas

ekstrem.

1.4 Batasan Masalah

Berikut adalah batasan yang diberlakukan dalam penelitian ini:

1. Arsitektur model yang dievaluasi berfokus pada keluarga MedMamba (MedMamba-T, MedMamba-S, dan MedMamba-B) dengan arsitektur CNN konvensional keluarga ResNet sebagai baseline pembanding eksternal yang dipasangkan pada kapasitas parameter yang setara, yaitu ResNet-18 (~11,2M) untuk MedMamba-T (~14,5M), ResNet-50 (~23,5M) untuk MedMamba-S (~22,8M), dan ResNet-101 (~44,5M) untuk MedMamba-B (~47,1M).
2. Dataset pengujian dibatasi secara spesifik pada citra dermatoskopi DermaMNIST-C beresolusi 224×224 piksel (7 kelas diagnosis lesi kulit) dengan menggunakan partisi baku terisolasi tingkat lesi (*lesion-level disjoint split*: 8.215 data latih, 573 data validasi, dan 1.227 data uji).
3. Seluruh varian model MedMamba dievaluasi sepenuhnya dari inisialisasi bobot acak (*random initialization / from scratch*) tanpa pemuatan bobot pra-pelatihan eksternal (*pre-trained weights*) guna memastikan perbandingan skalabilitas kapasitas parameter yang adil dan murni.
4. Paradigma pelatihan yang dikomparasikan mencakup *Supervised Learning* langsung berbasis *Class-Weighted Cross-Entropy Loss* dan *Supervised Contrastive Learning* (SupCon dua tahap) dengan strategi augmentasi stokastik terstandarisasi seragam dan pemuatan batch acak identik (*uniform random mini-batch sampling*) tanpa oversampling artifisial guna memastikan perbandingan yang adil (*ceteris paribus*).
5. Evaluasi kinerja model mencakup metrik performa klinis (*Balanced Accuracy*, *Macro Precision*, *Macro Recall*, *Macro F1-Score*, *Multiclass Matthews Correlation Coefficient*), reliabilitas kalibrasi prediksi (*Expected*

Calibration Error dan *Brier Score*), separabilitas fitur laten kuantitatif (k-NN dan *Silhouette Score*), serta efisiensi fisik perangkat keras (jumlah parameter, GFLOPs, latensi inferensi per sampel pada batch=1, dan konsumsi memori VRAM puncak).

6. Pelatihan dan pengujian dieksekusi pada lingkungan GPU server berbasis CUDA dengan protokol penguncian benih acak ganda (*multi-seed*, $N = 3$) dan estimasi ketidakpastian statistik sampel uji menggunakan metode *non-parametric bootstrap* ($B = 1.000$ iterasi) dengan pelaporan interval kepercayaan 95% (*95% Confidence Interval*).

1.5 Manfaat Penelitian

Manfaat yang diharapkan dari hasil penelitian ini meliputi:

1. Manfaat Akademis dan Teoritis: Memberikan kontribusi bukti empiris mengenai dinamika skalabilitas parameter arsitektur State Space Models (Mamba) pada domain citra medis dermatoskopi bebas kebocoran data, serta memperluas pemahaman teoritis mengenai interaksi antara representasi kontrastif supervisi (SupCon) dengan pemodelan sekuensial linear pada data sangat tidak seimbang.
2. Manfaat Praktis dan Klinis: Menyediakan panduan referensi arsitektur dan paradigma pelatihan yang optimal dan andal dalam mendeteksi jenis lesi kulit langka dan ganas tanpa mengorbankan efisiensi komputasi, guna mendukung pengembangan sistem diagnosis medis berbantuan komputer (*Computer-Aided Diagnosis*) yang lebih aman dan terkalibrasi.

1.6 Sistematika Penulisan

Laporan tugas akhir ini disusun ke dalam lima bab utama yang saling terhubung secara terstruktur sebagai berikut:

Bab I: Pendahuluan

Bab ini menguraikan latar belakang permasalahan mengenai klasifikasi penyakit kulit, ketidakseimbangan kelas ekstrem, kebocoran data pada DermaMNIST, serta komparasi paradigma pelatihan terhadap skalabilitas MedMamba. Selain itu, bab ini memuat rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, dan sistematika penulisan tugas akhir.

Bab II: Tinjauan Pustaka

Bab ini menyajikan kajian literatur sistematis dari penelitian terdahulu yang relevan serta landasan teori pendukung, mencakup karakteristik dataset DermaMNIST-C, penanganan data tidak seimbang, konsep dasar State Space Models dan arsitektur MedMamba, formulasi Supervised Contrastive Learning, serta formulasi metrik evaluasi klasifikasi multikelas, kalibrasi, dan efisiensi komputasi.

Bab III: Metode Penelitian

Bab ini menjelaskan diagram alur penelitian, tahapan akuisisi dan pra-pemrosesan data, konfigurasi spesifik arsitektur model, implementasi paradigma pelatihan terbobot dan kontrastif, rancangan matriks eksperimen faktorial, lingkungan perangkat lunak dan keras, serta protokol pengukuran metrik evaluasi.

Bab IV: Hasil dan Pembahasan

Bab ini memaparkan hasil pengujian eksperimen dari setiap skenario yang telah dirancang, analisis komparatif performa diagnostik, visualisasi pemisahan ruang laten fitur, kurva keandalan kalibrasi ECE, pengukuran efisiensi komputasi fisik perangkat keras, serta pembahasan kritis terhadap temuan yang diperoleh.

Bab V: Kesimpulan dan Saran

Bab ini merangkum kesimpulan menyeluruh yang menjawab rumusan masalah penelitian berdasarkan bukti eksperimental yang didapatkan, serta menyajikan saran-saran konstruktif untuk pengembangan penelitian lebih lanjut di masa mendatang.

BAB II
TINJAUAN PUSTAKA

2.1 Tinjauan Pustaka

Penelitian kecerdasan buatan dalam ranah klasifikasi citra medis dermatologi telah mengalami perkembangan yang pesat. Namun demikian, tinjauan literatur terkini mengindikasikan bahwa sebagian besar penelitian terdahulu berfokus pada arsitektur konvensional (CNN dan Vision Transformer) dan sering kali mengabaikan isu integritas pemisahan data pada dataset benchmarking. Penelitian ini diposisikan untuk menjembatani celah penelitian tersebut melalui studi komparatif berskala parameter dari arsitektur berbasis *State Space Models* (MedMamba) di bawah dua paradigma pelatihan yang berbeda pada dataset dermatoskopi bersih. Berikut merupakan beberapa kajian literatur yang menjadi referensi pada penelitian ini sebagai berikut:

1. Abhishek, Jain, dan Hamarneh (2025) [5] melakukan audit kualitas dataset secara menyeluruh terhadap dua benchmark dermatologi populer, yaitu DermaMNIST dan Fitzpatrick17k. Menggunakan pustaka analisis duplikasi *fastdup* dan inspeksi visual, penelitian tersebut membuktikan adanya kebocoran data (*data leakage*) sebesar **13,47%** (1.006 dari 7.470 lesi unik) pada DermaMNIST asli akibat pemisahan partisi latih, validasi, dan uji yang berbasis citra (*image-level split*), bukan lesi/pasien (*lesion-level split*). Temuan ini membuktikan bahwa benchmark terdahulu mengalami inflasi performa semu. Abhishek et al. menerbitkan dataset versi terkoreksi berupa **DermaMNIST-C** yang menerapkan partisi terisolasi tingkat lesi (*lesion-level disjoint split*) beresolusi 224×224 piksel melalui interpolasi bicubic langsung dari citra resolusi tinggi HAM10000.
2. Kadric, Akagic, dan Kapo (2025) [6] mengevaluasi performa arsitektur CNN modern (ResNet-50 dan EfficientNetV2L) dengan

pendekatan *transfer learning* pada DermaMNIST, dan melaporkan skor akurasi keseluruhan sebesar 85,1% (ResNet-50) dan 84,9% (EfficientNetV2L). Namun demikian, pengujian tersebut dieksekusi pada partisi DermaMNIST reguler yang belum disterilkan dari kebocoran data tingkat lesi. Selain itu, metrik akurasi keseluruhan yang dilaporkan sangat terdistorsi oleh dominasi kelas mayoritas (*Melanocytic Nevi* ~67%) tanpa menganalisis metrik keadilan prediksi pada kelas minoritas, serta berfokus murni pada arsitektur CNN konvensional tanpa mengevaluasi efisiensi linear *State Space Models* (Mamba) maupun paradigma *contrastive learning*.

3. Hariz (2026) [7] menganalisis performa ResNet-18 dan ResNet-50 pada DermaMNIST menggunakan teknik augmentasi minoritas terisolasi dan pembobotan penalti kelas (*class weights*). Studi tersebut menegaskan bahwa kelas minoritas ekstrem (seperti dermatofibroma dan lesi vaskular) tetap menjadi hambatan utama bagi model konvensional. Namun, pengujian tersebut masih dievaluasi pada partisi DermaMNIST orisinal yang memiliki kebocoran lesi serta menerapkan augmentasi asimetris yang berisiko mendistorsi densitas ruang representasi.
4. Yue dan Li (2024) [11] memperkenalkan **MedMamba**, arsitektur hibrida yang menggabungkan konvolusi lokal dengan modul *Visual State Space* (VSSM) berbasis pemindaian silang 4-arah (*Cross-Scan Module*) yang memiliki kompleksitas linear $O(N)$. MedMamba menunjukkan keunggulan akurasi dan efisiensi memori di atas ResNet dan Swin-ViT [14] pada berbagai modalitas citra medis MedMNIST. Namun, evaluasi MedMamba masih dilakukan pada partisi MedMNIST orisinal yang belum diaudit kebocorannya dan belum mengeksplorasi perbandingan empiris lintas varian skala parameter (Tiny, Small, Base).
5. Chen, Zhuang, dan Chang (2022) [15] merumuskan kerangka kerja **SuperCon** (*Supervised Contrastive Learning for Imbalanced Skin Lesion*

Classification) yang menerapkan pembelajaran kontrastif terawasi dua tahap khusus untuk menangani ketidakseimbangan kelas ekstrem pada klasifikasi lesi kulit dermatoskopi. Tahap pertama melatih representasi ruang laten menggunakan fungsi kerugian SupCon terawasi untuk menarik representasi intra-kelas dan merenggangkan jarak inter-kelas, diikuti oleh tahap kedua berupa pelatihan lapisan klasifikasi linier. Hasil penelitian mereka membuktikan bahwa SupCon mampu meningkatkan metrik Macro-F1 dan AUC secara signifikan pada kelas-kelas lesi kulit minoritas dibandingkan fungsi Cross-Entropy standar. Namun demikian, penelitian tersebut masih terbatas pada arsitektur CNN konvensional (ResNet dan EfficientNet), belum mengeksplorasi efisiensi komputasi linear *State Space Models* (MedMamba), belum mengkaji perilaku skalabilitas parameter multi-ukuran, serta masih dievaluasi pada partisi dataset yang rentan terhadap isu kebocoran data lesi.

Berdasarkan kajian terhadap kelima literatur di atas, *research gap* yang diidentifikasi adalah: belum adanya penelitian komprehensif yang membedah pengaruh variasi skala parameter arsitektur MedMamba (Tiny, Small, dan Base) saat dilatih dari awal (*scratch*) pada dataset dermatoskopi yang bersih dari kebocoran data (DermaMNIST-C), serta bagaimana interaksi arsitektur State Space Models tersebut ketika dilatih di bawah paradigma Supervised Learning terbobot dibandingkan paradigma Supervised Contrastive Learning (SupCon).

Tabel 2.1 Matriks Pembanding Penelitian Terdahulu

No.	**Judul & Penulis**	**Fokus Masalah**	**Metode & Dataset**	**Hasil & Keterbatasan**
1.	Kumar Abhishek, dkk. [2025] *[Investigating the Quality of DermaMNIST and Fitzpatrick17k]*	Kebocoran data (*data leakage*) dan duplikasi pada benchmark medis	Analisis duplikasi *fastdup*, evaluasi k-NN, dan pemisahan terisolasi lesi pada HAM10000	Menemukan kebocoran 13,47% pada DermaMNIST asli dan merilis *DermaMNIST-C* (224×224 bicubic). Belum mengevaluasi arsitektur Mamba.

No.	Judul & Penulis	Fokus Masalah	Metode & Dataset	Hasil & Keterbatasan
2.	Nerma Kadric, dkk. [2025] *[Improving Diagnostic Accuracy with CNNs: An Application on the DermaMNIST Dataset]*	Evaluasi efektivitas transfer learning CNN modern pada DermaMNIST	Eksplorasi performa ResNet-50 dan EfficientNetV2L pada DermaMNIST reguler	ResNet-50 mencapai akurasi 85,1% dan EfficientNetV2L 84,9%. Masih menggunakan split standar yang rentan kebocoran data lesi dan belum menguji arsitektur State Space Models (Mamba).
3.	Arkan Hariz [2026] *[Analisis Performa ResNet-18/50 dengan Augmentasi Minoritas]*	Ketidakseimbangan kelas ekstrem pada DermaMNIST	Augmentasi hibrida kelas minoritas dan pembobotan loss pada ResNet	Peningkatan recall minoritas pada citra 224, namun pengujian masih pada partisi DermaMNIST yang mengandung kebocoran data.

No.	Judul & Penulis	Fokus Masalah	Metode & Dataset	Hasil & Keterbatasan
4.	Yubiao Yue, dkk. [2024] *[MedMamba: Vision Mamba for Medical Image Classification]*	Kompleksitas kuadratik $O(N^2)$ pada ViT membebani memori komputasi	Hibrida Conv + Visual State Space Module (VSSM) $O(N)$ pada MedMNIST	Mengungguli ResNet dan Swin-ViT dalam akurasi dan memori. Pengujian masih pada MedMNIST orisinal (bocor) dan tanpa variasi skala komparatif.
5.	Keyu Chen, dkk. [2022] *[SuperCon: Supervised Contrastive Learning for Imbalanced Skin Lesion Classification]*	Ketimpangan kelas ekstrem dan degradasi performa minoritas pada citra dermatoskopi	Pembelajaran representasi SupCon dua tahap dilanjutkan fine-tuning classifier pada data tak seimbang	Terbukti meningkatkan Macro-F1 dan AUC kelas minoritas lesi kulit. Namun terbatas pada CNN konvensional, belum menguji State Space MedMamba dan belum dievaluasi pada dataset bebas kebocoran data.

2.2 Dasar Teori

Sub-bab ini menguraikan landasan teori yang menjadi dasar dalam penelitian ini.

2.2.1 DermaMNIST-C

DermaMNIST merupakan salah satu dataset dalam *MedMNIST v2* [16] yang diadaptasi dari koleksi dermatoskopi *HAM10000* (*Human Against Machine with 10000 training images*) [2]. Dataset ini mencakup 10.015 citra lesi kulit berpigmen yang mewakili lebih dari 95% varian lesi kulit yang sering dijumpai dalam praktik dermatologi rawat jalan [2].

Investigasi validitas data oleh Abhishek et al. (2025) [5] menemukan bahwa proses pemisahan partisi pada DermaMNIST orisinal yang membagi citra secara acak di tingkat file gambar (*image-level split*). Akibatnya, beberapa foto berbeda dari lesi atau pasien yang sama tersebar ke dalam himpunan latih dan himpunan pengujian secara bersamaan, sehingga menghasilkan kebocoran data sebesar 13,47% (1.006 lesi bocor dari 7.470 lesi unik). Selain itu, citra resolusi 224×224 pada DermaMNIST asli dibentuk melalui interpolasi *nearest-neighbor* dari matriks 28×28, yang mengaburkan tekstur mikroskopis dermatoskopi.

DermaMNIST-C menyelesaikan kecacatan ini melalui pemisahan terisolasi di tingkat lesi (*lesion-level disjoint split*), di mana seluruh citra dari lesi yang sama dijamin berada pada partisi yang sama persis, serta dilakukan pemotongan dan penyesuaian ukuran langsung dari citra mentah dengan resolusi tinggi (600×450 piksel) menggunakan interpolasi *bicubic* [5]. Distribusi resmi ketujuh kelas pada DermaMNIST-C dirangkum dalam Tabel 2.2.

Tabel 2.2 Distribusi Sampel per Kelas pada Partisi Baku DermaMNIST-C

ID	Nama Diagnosis Medis	Kode	Latih	Validasi	Uji	Total
0	Actinic Keratoses & Intraepithelial Ca.	`akiec`	276	19	32	327 (3,27%)
1	Basal Cell Carcinoma	`bcc`	420	30	64	514 (5,13%)
2	Benign Keratosis-like Lesions	`bkl`	899	63	137	1.099 (10,97%)
3	Dermatofibroma	`df`	94	7	14	115 (1,15%)
4	Melanoma	`mel`	911	64	138	1.113 (11,11%)
5	Melanocytic Nevi	`nv`	5.500	382	823	6.705 (66,95%)
6	Vascular Lesions	`vasc`	115	8	19	142 (1,42%)
Total Citra			**8.215**	**573**	**1.227**	**10.015**

Karakteristik klinis dan patologi dari ketujuh kelas lesi kulit tersebut diuraikan sebagai berikut:

2.2.1.1 Actinic Keratoses and Intraepithelial Carcinoma (`akiec`)

Actinic Keratoses (AK) merupakan lesi pra-kanker intraepitelial yang timbul akibat proliferasi keratinosit atipik epidermal yang dipicu paparan sinar ultraviolet kronis [17]. Apabila atypia selular meluas ke seluruh ketebalan lapisan epidermis namun membran basalis masih utuh (*intact*), lesi ini diklasifikasikan sebagai karsinoma intraepitelial (*Bowen's disease* atau *squamous cell carcinoma in-situ*). Ketika sel atypik tersebut menembus membran basalis dan menyerang lapisan dermis, lesi berevolusi menjadi *Invasive Squamous Cell Carcinoma* (SCC). Pada DermaMNIST-C, kelas `akiec` mencakup spektrum AK dan karsinoma intraepitelial, dengan total 327 sampel (3,27%). Contoh sampel citra dermatoskopi untuk kelas `akiec` disajikan pada Gambar 2.1.



Gambar 2.1 Contoh Sampel Citra Dermatoskopi Kelas *Actinic Keratoses and Intraepithelial Carcinoma* (akiec)

2.2.1.2 Basal Cell Carcinoma (bcc)

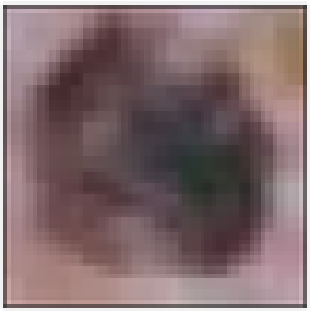
Basal Cell Carcinoma (BCC) merupakan keganasan kulit non-melanoma paling umum yang timbul dari sel-sel basal pada lapisan epidermis terdalam [2]. Meskipun memiliki laju metastasis rendah, pertumbuhan destruktif lokalnya dapat menyebabkan kerusakan jaringan signifikan bila tidak diangkat. Kategori bcc mencakup 514 sampel (5,13%). Contoh sampel citra dermatoskopi untuk kelas bcc disajikan pada Gambar 2.2.



Gambar 2.2 Contoh Sampel Citra Dermatoskopi Kelas *Basal Cell Carcinoma* (bcc)

2.2.1.3 Benign Keratosis-Like Lesions (`bkl`)

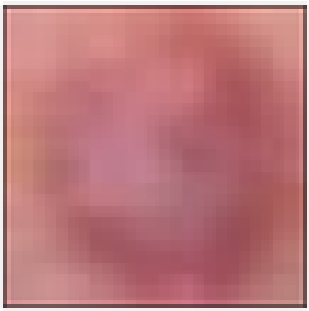
Benign Keratosis-Like Lesions (BKL) adalah kategori gabungan dari lesi epitelial jinak, mencakup *seborrheic keratoses*, *solar lentigo*, dan *lichen planus-like keratoses* [2]. Ketiganya dikelompokkan bersama karena kesamaan biologis dan pola visual dermatoskopik yang beririsan. Kategori `bkl` berjumlah 1.099 sampel (10,97%). Contoh sampel citra dermatoskopi untuk kelas `bkl` disajikan pada Gambar 2.3.



Gambar 2.3 Contoh Sampel Citra Dermatoskopi Kelas *Benign Keratosis-Like Lesions* (`bkl`)

2.2.1.4 Dermatofibroma (`df`)

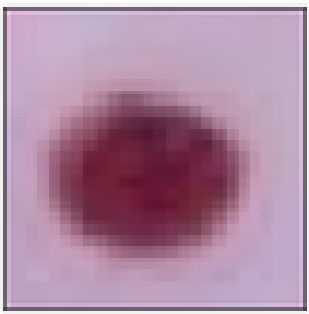
Dermatofibroma adalah lesi kulit jinak berbentuk nodul dermal yang muncul sebagai respons proliferasi fibroblas terhadap trauma fisik ringan. Secara dermatoskopi ditandai oleh jaring pigmen retikular di bagian tepi dengan bercak putih di pusat lesi (*central white patch*). Kelas `df` merupakan **kelas paling minoritas** dengan total 115 sampel (1,15%). Contoh sampel citra dermatoskopi untuk kelas `df` disajikan pada Gambar 2.4.



Gambar 2.4 Contoh Sampel Citra Dermatoskopi Kelas *Dermatofibroma* (`df`)

2.2.1.5 Melanoma (`mel`)

Melanoma merupakan neoplasma ganas paling mematikan pada kulit yang berasal dari transformasi keganasan melanosit [2]. Lesi ini memiliki potensi metastasis yang sangat agresif. Pola visualnya ditandai oleh asimetri, batas ireguler, variasi warna tajam, dan jaringan pigmen atypik. Kategori `mel` mencakup 1.113 sampel (11,11%). Contoh sampel citra dermatoskopi untuk kelas `mel` disajikan pada Gambar 2.5.



Gambar 2.5 Contoh Sampel Citra Dermatoskopi Kelas *Melanoma* (`mel`)

2.2.1.6 Melanocytic Nevi (`nv`)

Melanocytic Nevi (tahi lalat) merupakan proliferasi jinak melanosit yang bersifat non-maligna dengan risiko transformasi ganas yang sangat rendah.

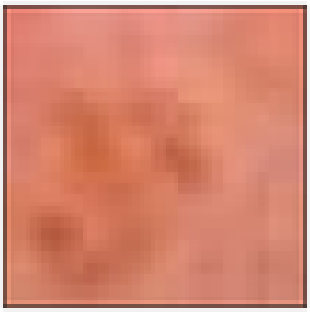
Pada DermaMNIST-C, kelas nv merupakan **kelas mayoritas dominan** yang mencakup 6.705 sampel (66,95%). Contoh sampel citra dermatoskopi untuk kelas nv disajikan pada Gambar 2.6.



Gambar 2.6 Contoh Sampel Citra Dermatoskopi Kelas *Melanocytic Nevi* (nv)

2.2.1.7 Vascular Lesions (vasc)

Vascular Lesions mencakup anomali pembuluh darah kulit yang bersifat jinak, seperti angioma, angiokeratoma, dan granuloma piogenik. Karakteristik visualnya ditandai oleh laguna vaskular berwarna merah atau biru keunguan (*red clods*). Kelas ini tergolong kelas minoritas dengan 142 sampel (1,42%). Contoh sampel citra dermatoskopi untuk kelas vasc disajikan pada Gambar 2.7.



Gambar 2.7 Contoh Sampel Citra Dermatoskopi Kelas *Vascular Lesions* (vasc)

2.2.2 Ketidakseimbangan Data (*Imbalanced Data*)

Masalah ketidakseimbangan data terjadi ketika perbandingan frekuensi kemunculan sampel antar-kelas sangat tidak setara [4]. Pada DermaMNIST-C, rasio antara kelas mayoritas (`nv`: 5.500 citra latih) terhadap kelas paling minoritas (`df`: 94 citra latih) mencapai hampir 59:1. Kondisi ketimpangan ini menyebabkan *Cross-Entropy* standar terdominasi oleh gradien akumulasi dari kelas mayoritas, sehingga model cenderung memprediksi seluruh sampel sebagai kelas mayoritas untuk meminimalkan total *loss* [4].

Untuk mengompensasi bias gradien tersebut, diterapkan *Class-Weighted Cross-Entropy Loss* ($\mathcal{L}_{CWCE}$), yang memberikan bobot penalti lebih besar pada kelas minoritas [4], [18]:

$$\mathcal{L}_{CWCE} = -\sum_{k=1}^{K} w_k \cdot y_k \log(\hat{y}_k) \qquad \text{(Rumus 2.1)}$$

Di mana $y_k \in \{0, 1\}$ adalah label *ground-truth*, $\hat{y}_k$ adalah probabilitas prediksi keluaran softmax, dan bobot kelas w_k dihitung berdasarkan frekuensi terbalik sampel pada himpunan data latih [4], [18]:

$$w_k = \frac{N_{train}}{K \cdot N_{train,k}} \qquad \text{(Rumus 2.2)}$$

dengan N_{train} menyatakan total sampel pada partisi latih ($N_{train} = 8.215$), K adalah jumlah kelas ($K = 7$), dan $N_{train,k}$ adalah jumlah sampel latih pada kelas k.

2.2.3 Bias Induktif CNN dan Karakteristik Vision Transformer (ViT)

Jaringan saraf tiruan konvolusional (*Convolutional Neural Networks* / CNN) mengandalkan operasi konvolusi lokal dengan pembagian bobot (*shared weights*) dan invarian translasi (*translation invariance*), yang memberikan keunggulan bias induktif spasial (*spatial inductive bias*) yang kokoh [3]. Karakteristik ini memungkinkan ekstraksi fitur visual berjenjang secara efisien

dari tepian primitif hingga bentuk kompleks. Namun demikian, keterbatasan bidang reseptif (*receptive field*) kernel konvolusi menyebabkan CNN kesulitan menangkap konteks lesi yang membutuhkan ketergantungan jarak jauh (*long-range dependencies*), kecuali melalui penumpukan lapisan yang sangat dalam atau operasi penggabungan spasial (*pooling*) yang berisiko menghilangkan detail tekstur mikroskopis dermatoskopi.

Untuk mengatasi limitasi bidang reseptif lokal tersebut, *Vision Transformer* (ViT) [8] mengadaptasi mekanisme *Multi-Head Self-Attention* (MHSA) dari ranah pemrosesan bahasa alami ke ranah visi komputer. Citra masukan diproyeksikan menjadi sekuens token *patch* 2D, memungkinkan setiap token berinteraksi secara global dengan seluruh token lainnya di setiap lapisan. Akan tetapi, komputasi matriks atensi berpasangan pada ViT menuntut biaya waktu dan konsumsi memori berorde kuadratik $O(N^2)$ terhadap panjang sekuens token N [9]. Di samping itu, ketiadaan bias induktif lokal bawaan menyebabkan ViT bersifat sangat lapar data (*data-hungry*), sehingga rentan mengalami kegagalan generalisasi atau konvergensi suboptimal apabila dilatih dari awal (*from scratch*) pada dataset citra medis berukuran terbatas seperti DermaMNIST-C tanpa inisialisasi bobot prapelatihan berskala masif.

2.2.4 Arsitektur Residual Networks (ResNet)

Sebagai arsitektur kanonikal yang mewakili paradigma konvolusional modern, *Residual Networks* (ResNet) [19] mengatasi masalah degradasi akurasi (*degradation problem*) pada jaringan yang sangat dalam. Fenomena degradasi ini ditandai oleh saturasi akurasi yang diikuti penurunan tajam performa seiring bertambahnya kedalaman jaringan, yang bukan diakibatkan oleh *overfitting*, melainkan oleh kendala optimasi akibat hilangnya gradien (*vanishing gradient*) saat propagasi balik melalui rantai perkalian bobot berulang [19].

He et al. (2016) [19] merumuskan solusi melalui konsep pembelajaran residual (*deep residual learning*). Alih-alih mengoptimalkan pemetaan target

laten $\mathcal{H}(\mathbf{x})$ secara langsung dari tumpukan lapisan non-linier, lapisan tersebut dipaksa mempelajari fungsi residual $\mathcal{F}(\mathbf{x}) = \mathcal{H}(\mathbf{x}) - \mathbf{x}$. Fungsi luaran akhir disusun melalui penambahan koneksi jalan pintas identitas (*identity shortcut connection*):

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x} \qquad \text{(Rumus 2.3)}$$

di mana $\mathbf{x}$ dan $\mathbf{y}$ masing-masing merepresentasikan vektor masukan dan keluaran dari blok residual yang dievaluasi, dan $\mathcal{F}(\mathbf{x}, \{W_i\})$ menyatakan pemetaan residual konvolusional yang dipelajari. Apabila terjadi diskrepansi dimensi kanal atau resolusi spasial antara masukan dan keluaran, koneksi pintas diproyeksikan secara linier menggunakan matriks W_s:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + W_s\mathbf{x} \qquad \text{(Rumus 2.4)}$$

Secara analitis, formulasi ini memungkinkan gradien kesalahan dari lapisan atas mengalir langsung tanpa hambatan ke lapisan awal melalui operator identitas ($\frac{\partial \mathcal{E}}{\partial \mathbf{x}} = \frac{\partial \mathcal{E}}{\partial \mathbf{y}} \left(\frac{\partial \mathcal{F}}{\partial \mathbf{x}} + \mathbf{I} \right)$), memfasilitasi konvergensi jaringan hingga puluhan maupun ratusan lapisan.

Struktur blok penyusun keluarga ResNet terbagi menjadi dua konfigurasi utama berdasarkan kedalamannya:

1. ***Basic Residual Block*** (diimplementasikan pada ResNet-18 dan ResNet-34): Tersusun atas dua lapisan konvolusi berukuran 3×3 yang masing-masing diikuti oleh normalisasi tumpak (*Batch Normalization*) dan fungsi aktivasi non-linier ReLU. Blok ini menjaga beban komputasi tetap proporsional pada skala parameter yang ringkas.
2. ***Bottleneck Residual Block*** (diimplementasikan pada ResNet-50, ResNet-101, dan ResNet-152): Dirancang khusus untuk menekan kebutuhan komputasi FLOPs dan parameter pada kedalaman tinggi melalui struktur tiga lapisan bertingkat: konvolusi 1×1 untuk mereduksi dimensi kanal (*squeeze*), konvolusi 3×3 untuk ekstraksi fitur spasial pada ruang

berdimensi terkompresi, dan konvolusi 1×1 untuk merestorasi dimensi kanal (*expand*) sebelum dijumlahkan dengan jalur *residual shortcut*.

Dalam penelitian ini, keluarga ResNet ditetapkan sebagai *external scale-matched baseline* berparadigma konvolusi murni untuk menguji apakah keunggulan komputasi dan akurasi MedMamba konsisten di setiap tingkatan skala parameter. Tiga varian ResNet dipilih secara presisi berdasarkan kedekatan kapasitas parameternya:

- **ResNet-18** (~11,2M parameter, 8 blok residual dasar) sebagai pembanding terhadap **MedMamba-T** (~14,5M parameter).
- **ResNet-50** (~23,5M parameter, 16 blok residual *bottleneck*) sebagai pembanding terhadap **MedMamba-S** (~22,8M parameter).
- **ResNet-101** (~44,5M parameter, 33 blok residual *bottleneck*) sebagai pembanding terhadap **MedMamba-B** (~47,1M parameter).

2.2.5 Arsitektur State Space Models (SSM) dan MedMamba

2.2.5.1 State Space Models (SSM)

State Space Models (SSM) memodelkan sistem dinamik sekuensial kontinu yang memetakan sinyal masukan $x(t) \in \mathbb{R}$ ke keluaran $y(t) \in \mathbb{R}$ melalui variabel keadaan laten tersembunyi $h(t) \in \mathbb{R}^D$ dengan matriks evolusi $\mathbf{A} \in \mathbb{R}^{D \times D}$, vektor proyeksi masukan $\mathbf{B} \in \mathbb{R}^{D \times 1}$, dan vektor pembaca keluaran $\mathbf{C} \in \mathbb{R}^{1 \times D}$:

$$\begin{aligned} h'(t) &= \mathbf{A}h(t) + \mathbf{B}x(t) \\ y(t) &= \mathbf{C}h(t) \end{aligned} \qquad \text{(Rumus 2.5)}$$

Untuk pemrosesan data diskrit digital, sistem kontinu di atas didiskretisasi menggunakan aturan *Zero-Order Hold* (ZOH) dengan parameter langkah waktu

(*step size*) $\mathbf{\Delta}$:

$$\begin{aligned}\bar{\mathbf{A}} &= \exp(\mathbf{\Delta A}) \\ \bar{\mathbf{B}} &= (\mathbf{\Delta A})^{-1}(\bar{\mathbf{A}} - \mathbf{I}) \cdot (\mathbf{\Delta B}) \\ h_t &= \bar{\mathbf{A}} h_{t-1} + \bar{\mathbf{B}} x_t \\ y_t &= \mathbf{C} h_t\end{aligned} \tag{Rumus 2.6}$$

Keunggulan utama arsitektur **Mamba** terletak pada pengenalan *Selective Scan Mechanism* (S6) [10]. Berbeda dengan model SSM linier statis terdahulu (seperti S4) di mana parameter $\mathbf{A}, \mathbf{B}, \mathbf{C}$ bersifat konstan invarian waktu (*Linear Time-Invariant*), Mamba merumuskan parameter $\mathbf{B}$, $\mathbf{C}$, dan $\mathbf{\Delta}$ sebagai fungsi terbobot langsung dari token masukan x_t:

$$\begin{aligned}\mathbf{B}_t &= \text{Linear}_N(x_t), \quad \mathbf{C}_t = \text{Linear}_N(x_t) \\ \mathbf{\Delta}_t &= \text{softplus}(\text{Parameter} + \text{Linear}_D(x_t))\end{aligned} \tag{Rumus 2.7}$$

Mekanisme seleksi adaptif ini memungkinkan model menyaring informasi relevan dan melupakan informasi yang tidak penting di sepanjang sekuens dengan kompleksitas komputasi linear $O(N)$ [10].

2.2.5.2 MedMamba

Arsitektur MedMamba [11] mengadaptasi prinsip SSM visual ke ranah citra medis melalui blok modular **SS-Conv-SSM**. Blok ini menggabungkan cabang konvolusi lokal (menggunakan depthwise convolution untuk menangkap tekstur mikroskopis dermatoskopi) dengan cabang *Visual State Space Module* (VSSM). Modul VSSM mengintegrasikan *Cross-Scan Module* (CSM) [20] yang memindai representasi fitur 2D ke dalam empat arah spasial yang berbeda (kiri-ke-kanan, kanan-ke-kiri, atas-ke-bawah, dan bawah-ke-atas) guna menangkap ketergantungan spasial multi-arah tanpa memunculkan bias directional scan.

Penelitian ini mengevaluasi skalabilitas kapasitas representasi MedMamba melalui tiga konfigurasi skala resmi [11]:

- **MedMamba-T (*Tiny*):** Dikonfigurasi dengan kedalaman per stage `depths = [2, 2, 4, 2]` dan dimensi kanal `dims = [96, 192, 384, 768]` (~14,5M parameter pada 7 kelas).
- **MedMamba-S (*Small*):** Dikonfigurasi dengan kedalaman per stage `depths = [2, 2, 8, 2]` dan dimensi kanal `dims = [96, 192, 384, 768]` (~22,8M parameter pada 7 kelas) — ditetapkan sebagai **model fokus utama studi**.
- **MedMamba-B (*Base*):** Dikonfigurasi dengan kedalaman per stage `depths = [2, 2, 12, 2]` dan dimensi kanal `dims = [128, 256, 512, 1024]` (~47,1M parameter pada 7 kelas).

2.2.6 Paradigma Pelatihan: Supervised vs. Contrastive Learning

Penelitian ini membandingkan dua paradigma pelatihan mendasar:

2.2.6.1 Paradigma Supervised Learning Langsung

Pada paradigma ini, model dilatih secara *end-to-end* dari input citra langsung menuju probabilitas kelas menggunakan fungsi objektif $\mathcal{L}_{CWCE}$. Gradien kesalahan dialirkan langsung dari lapisan klasifikasi ke seluruh backbone arsitektur untuk meminimalkan log-loss empiris.

2.2.6.2 Paradigma Supervised Contrastive Learning (SupCon)

Paradigma *Supervised Contrastive Learning* [13] memisahkan proses pembelajaran menjadi dua tahap terpisah. Pada tahap pertama (*contrastive pre-training*), setiap citra masukan x_k ditransformasi menjadi dua tampilan acak (*two random augmented views*) $\tilde{x}_{2k-1}$ dan $\tilde{x}_{2k}$, membentuk batch berukuran $2N$. Citra tersebut diekstraksi fiturnya oleh backbone MedMamba $f(\cdot)$ menjadi representasi $r = f(\tilde{x})$, lalu diproyeksikan ke ruang laten berdimensi rendah ($d = 128$) oleh *Projection Head* $g(\cdot)$ non-linier 2-layer MLP, menghasilkan

vektor laten terproyeksi yang dinormalisasi pada bola unit:

$$z_i = \frac{g(f(\tilde{x}_i))}{\|g(f(\tilde{x}_i))\|_2} \qquad \text{(Rumus 2.8)}$$

Fungsi kerugian SupCon ($\mathcal{L}_{SupCon}$) memaksimalkan dot-product pasangan sampel dari kelas yang sama dan meminimalkan dot-product pasangan sampel dari kelas berbeda:

$$\mathcal{L}_{SupCon} = \sum_{i \in I} \frac{-1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(z_i \cdot z_p / \tau)}{\sum_{a \in A(i)} \exp(z_i \cdot z_a / \tau)} \qquad \text{(Rumus 2.9)}$$

di mana $I \equiv \{1, \ldots, 2N\}$ adalah indeks seluruh tampilan teraugmentasi dalam batch, $A(i) \equiv I \setminus \{i\}$, $P(i) \equiv \{p \in A(i) : y_p = y_i\}$ adalah himpunan indeks sampel yang memiliki label diagnosis identik dengan sampel i, $|P(i)|$ menyatakan kardinalitas himpunan positif, dan $\tau > 0$ adalah parameter temperatur ($\tau = 0,07$). Pada tahap kedua, *projection head* dibuang dan lapisan klasifikasi linier dipasang di atas representasi fitur beku (*frozen*) atau di-fine-tune untuk memprediksi label diagnosis.

2.2.7 Metrik Evaluasi, Kalibrasi, dan Efisiensi Komputasi

Kinerja arsitektur diukur secara menyeluruh melalui tiga pilar evaluasi:

2.2.7.1 Metrik Kinerja Diagnostik Multikelas

Berdasarkan nilai matriks kontingensi multikelas (*Confusion Matrix*), dihitung metrik berikut untuk menghindari bias populasi mayoritas [21]:

$$\text{Balanced Accuracy} = \frac{1}{K} \sum_{k=1}^{K} \frac{TP_k}{TP_k + FN_k} \qquad \text{(Rumus 2.10)}$$

$$\text{Macro Precision} = \frac{1}{K} \sum_{k=1}^{K} \frac{TP_k}{TP_k + FP_k} \qquad \text{(Rumus 2.11)}$$

$$\text{Macro F1-Score} = \frac{1}{K}\sum_{k=1}^{K}\frac{2 \cdot \text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k} \qquad \text{(Rumus 2.12)}$$

Selain itu, dihitung *Multiclass Matthews Correlation Coefficient* (MCC) menurut formulasi Gorodkin (2004) [22]:

$$\text{MCC} = \frac{C \cdot N - \sum_{k=1}^{K} p_k t_k}{\sqrt{\left(N^2 - \sum_{k=1}^{K} p_k^2\right)\left(N^2 - \sum_{k=1}^{K} t_k^2\right)}} \qquad \text{(Rumus 2.13)}$$

di mana K adalah jumlah kelas ($K = 7$), N adalah total sampel uji, $C = \sum_{k=1}^{K} TP_k$ adalah total prediksi benar, $p_k = \sum_{j=1}^{K} M_{jk}$ adalah total sampel yang diprediksi ke kelas k, dan $t_k = \sum_{j=1}^{K} M_{kj}$ adalah total sampel aktual kelas k. MCC memberikan skor pada rentang $[-1, +1]$ dan bersifat tahan (*robust*) terhadap ketidakseimbangan kelas ekstrem.

2.2.7.2 Metrik Reliabilitas Kalibrasi Prediksi

Untuk mengevaluasi apakah tingkat kepastian (*confidence score*) selaras dengan probabilitas kebenaran prediksi klinis, dievaluasi dua metrik kalibrasi probabilistik:

1. **Expected Calibration Error (ECE)** [23]: Mengukur rata-rata selisih absolut terbobot antara tingkat kepercayaan prediksi dengan akurasi aktual sampel yang dikelompokkan ke dalam M interval bin yang terbagi rata ($M = 10$):

$$\text{ECE} = \sum_{m=1}^{M}\frac{|B_m|}{N}\left|\text{acc}(B_m) - \text{conf}(B_m)\right| \qquad \text{(Rumus 2.14)}$$

   di mana $\text{acc}(B_m)$ dan $\text{conf}(B_m)$ masing-masing merepresentasikan akurasi dan rata-rata skor kepercayaan di dalam bin B_m.

2. **Brier Score** [24]: Mengukur kesalahan kuadrat rata-rata antara vektor probabilitas keluaran model dengan representasi biner *one-hot* label

ground-truth:

$$\text{Brier Score} = \frac{1}{N}\sum_{i=1}^{N}\sum_{k=1}^{K}\left(\hat{p}_{i,k} - y_{i,k}\right)^2 \qquad \text{(Rumus 2.15)}$$

di mana N menyatakan total sampel uji, K adalah jumlah kelas ($K = 7$), $\hat{p}_{i,k} \in [0, 1]$ adalah probabilitas prediksi untuk kelas k pada sampel i, dan $y_{i,k} \in \{0, 1\}$ adalah indikator ground-truth.

2.2.7.3 Metrik Efisiensi Komputasi Hardware

Evaluasi komputasi fisik mencakup pemodelan beban komputasi teoritis dan profil performa perangkat keras:

1. **Jumlah Parameter (M_{param})**: Akumulasi parameter terbobot jaringan yang dihitung dari total elemen tensor bobot dan bias pada seluruh lapisan L:

$$M_{\text{param}} = \frac{1}{10^6}\sum_{l=1}^{L}\left(\text{numel}(W_l) + \text{numel}(b_l)\right) \qquad \text{(Rumus 2.16)}$$

2. **Giga Floating Point Operations (GFLOPs)**: Total operasi aritmatika titik kambang (perkalian dan penjumlahan) yang dieksekusi selama propagasi maju untuk memproses satu citra masukan berdimensi $224 \times 224 \times 3$:

$$\text{GFLOPs} = \frac{\text{Total FLOPs}}{10^9} \qquad \text{(Rumus 2.17)}$$

3. **Throughput Inferensi**: Kecepatan pemrosesan citra per satuan waktu yang dihitung pada ukuran batch penuh saat inferensi:

$$\text{Throughput} = \frac{N_{\text{batch}}}{T_{\text{inferensi}}} \quad \text{(citra/detik)} \qquad \text{(Rumus 2.18)}$$

4. **Latensi Inferensi (*Inference Latency*)**: Waktu eksekusi rata-rata propagasi maju per citra pada ukuran batch=1 dalam satuan milidetik

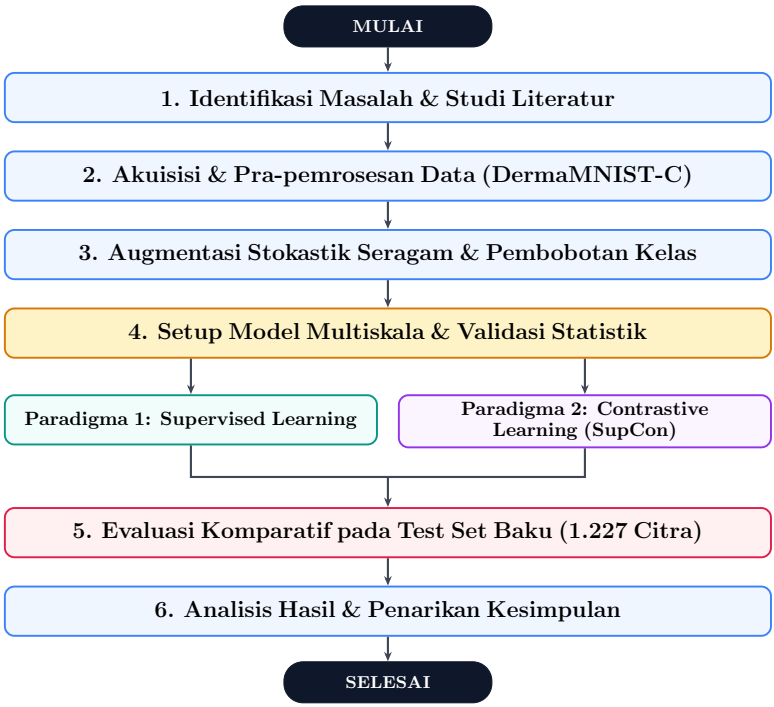
(ms).

5. **Konsumsi Memori VRAM Puncak (*Peak VRAM*)**: Alokasi memori GPU maksimal selama siklus pelatihan (propagasi maju dan propagasi balik gradien) dalam satuan Megabyte (MB) atau Gigabyte (GB).

BAB III
METODE PENELITIAN

3.1 Alur Penelitian

Penelitian ini dirancang secara sistematis untuk mengevaluasi skalabilitas arsitektur MedMamba (skala Tiny, Small, dan Base) di bawah dua paradigma pelatihan yang berbeda (Supervised Learning terbobot vs. Supervised Contrastive Learning) pada dataset dermatoskopi bebas kebocoran data (DermaMNIST-C). Tahapan pelaksanaan penelitian ditunjukkan pada diagram alir (*flowchart*) pada Gambar 3.1.



Gambar 3.1 Alur Penelitian

3.2 Penjabaran Langkah Penelitian

Penjelasan rinci mengenai setiap tahapan penelitian pada diagram alir diuraikan sebagai berikut:

3.2.1 Identifikasi Masalah

Tahap awal penelitian dilakukan dengan menelaah tantangan komputasi dan metodologis pada klasifikasi citra lesi kulit. Ditemukan bahwa penelitian terdahulu pada DermaMNIST menghadapi ketimpangan kelas yang sangat ekstrem (Melanocytic Nevi ~67% vs Dermatofibroma ~1,15%) yang memicu bias prediksi pada model konvensional [4]. Selain itu, investigasi data oleh Abhishek et al. (2025) [5] membuktikan bahwa DermaMNIST asli mengalami kebocoran data sebesar 13,47% akibat pemisahan berbasis citra (*image-level split*). Di sisi arsitektur, Vision Transformer menuntut komputasi kuadratik $O(N^2)$ yang berat [9]. Berdasarkan permasalahan tersebut, penelitian ini memformulasikan studi komparatif arsitektur State Space Models (MedMamba) ber-kompleksitas linear $O(N)$ pada dataset DermaMNIST-C yang bersih dari kebocoran data.

3.2.2 Studi Literatur

Tahap studi literatur dilakukan dengan mengkaji landasan akademis yang mencakup: prinsip dasar pemodelan sekuensial State Space Models dan mekanisme pemindaian selektif Mamba (S6) [10], [11], bukti empiris kebocoran data pada benchmark medis [5], formulasi manifold representasi kontrastif terawasi (SupCon) [13], teknik penanganan ketidakseimbangan kelas berbasis bobot penalti terbalik [4], [18], serta metrik evaluasi diagnostik dan kalibrasi probabilitas klinis (ECE) [22], [23].

3.2.3 Akuisisi Dataset

Dataset yang digunakan dalam penelitian ini adalah **DermaMNIST-C** yang diakuisisi dari repositori resmi Zenodo konsorsium audit data medis [5].

Dataset ini terdiri dari 10.015 citra dermatoskopi terstandarisasi yang dibagi ke dalam 7 kategori diagnosis medis. Seluruh citra telah terbebas dari kebocoran data melalui penerapan pemisahan terisolasi di tingkat lesi/pasien (*lesion-level disjoint split*) dengan pembagian partisi baku: 8.215 data latih (*train*), 573 data validasi (*val*), dan 1.227 data uji (*test*). Dataset diunduh langsung dalam format citra beresolusi 224×224 piksel yang dihasilkan melalui interpolasi *bicubic* dari citra asli beresolusi tinggi HAM10000.

3.2.4 Preprocessing Data

Tahap pra-pemrosesan data dilakukan untuk memastikan tensor citra siap diproses oleh arsitektur model:

1. Verifikasi Dimensi: Memastikan seluruh citra berada pada dimensi seragam $224 \times 224 \times 3$ piksel RGB berformat tensor *floating-point* $[0.0, 1.0]$.
2. Normalisasi Z-Score: Citra dinormalisasi menggunakan nilai rata-rata (*mean*) dan deviasi standar (*standard deviation*) saluran warna RGB. Untuk mencegah kebocoran informasi statistik (*data snooping*), parameter normalisasi dihitung secara ketat **hanya dari himpunan data latih** ($\mu_{train} = [0,763, 0,538, 0,561]$ dan $\sigma_{train} = [0,140, 0,152, 0,169]$), lalu diterapkan ke himpunan validasi dan pengujian.

3.2.5 Augmentasi Data dan Penanganan Data Tak Seimbang

Guna memastikan komparasi yang adil (*ceteris paribus*) dan memenuhi kaidah metodologi kedua paradigma pelatihan, strategi penanganan data dirancang secara sistematis:

1. **Augmentasi Stokastik Seragam**: Pipeline transformasi stokastik diterapkan secara identik ke seluruh sampel dari semua kelas selama fase pelatihan guna memperluas variabilitas spasial dan mencegah penghafalan piksel. Transformasi mencakup: pemotongan acak berskala (*Random*

Resized Crop, skala 0.7 – 1.0, rasio aspek 3/4 – 4/3), pembalikan horizontal acak (*Random Horizontal Flip*, $p = 0.5$), pembalikan vertikal acak (*Random Vertical Flip*, $p = 0.5$), rotasi acak rentang ±15°, serta manipulasi fotometrik ringan (*Color Jitter*: kecerahan=0.1, kontras=0.1, saturasi=0.1).

2. **Pemuatan Batch Acak Seragam dan Pembentukan Multi-View SupCon**: Untuk menjaga agar efek paradigma tidak tercampur (*confounded*) dengan artefak teknik sampling, kedua paradigma menggunakan strategi pemuatan batch yang identik, yaitu ***Uniform Random Mini-Batch Sampling*** tanpa melakukan *oversampling* minoritas buatan. Dengan strategi ini, definisi satu epoch tetap terjaga secara konsisten dan terukur ($N_{train} = 8.215$ citra unik per epoch atau 257 iterasi pada ukuran batch $N = 32$). Khusus pada paradigma SupCon, setiap citra dalam batch ditransformasi dua kali secara independen melalui pipeline augmentasi stokastik di atas, menghasilkan $2N = 64$ tampilan per batch. Berdasarkan formulasi Khosla et al. (2020) [13], setiap sampel i dijamin memiliki minimal satu pasangan positif, yaitu tampilan teraugmentasi dirinya sendiri ($|P(i)| \geq 1$), serta berpasangan dengan sampel sekelas lainnya yang hadir secara natural dalam batch.
3. **Penanganan Ketidakseimbangan Kelas pada Fungsi Kerugian**: Mengingat distribusi sampling dibiarkan alami tanpa sintesis data asimetris, ketimpangan proporsi kelas ditangani murni pada level fungsi objektif menggunakan *Class-Weighted Cross-Entropy Loss* ($\mathcal{L}_{CWCE}$) [4], [18], di mana bobot penalti dihitung berdasarkan frekuensi terbalik sampel latih:

$$w_k = \frac{N_{train}}{K \cdot N_{train,k}} \qquad \text{(Rumus 3.1)}$$

sehingga kesalahan prediksi pada kelas minoritas seperti `df` ($N_{train,df} = 94$) dan `vasc` ($N_{train,vasc} = 115$) mendapatkan bobot gradien penalti

puluhan kali lebih besar dibandingkan kelas mayoritas nv ($N_{train,nv}$ = 5.500).

3.2.6 Perancangan Model dan Skenario Pelatihan

Tahap perancangan model mengevaluasi tiga skala arsitektur MedMamba [11]: MedMamba-T (~14,5M parameter), MedMamba-S (~22,8M parameter), dan MedMamba-B (~47,1M parameter), serta menyertakan keluarga model konvensional ResNet berparameter sepadan sebagai baseline pembanding eksternal di setiap tingkatan skala: ResNet-18 (~11,2M parameter untuk MedMamba-T), ResNet-50 (~23,5M parameter untuk MedMamba-S), dan ResNet-101 (~44,5M parameter untuk MedMamba-B).

Model dilatih di bawah dua paradigma:

1. Paradigma Supervised Learning: Model dilatih secara langsung menggunakan optimizer AdamW, penjadwal laju pembelajaran Cosine Annealing, dan fungsi kerugian $\mathcal{L}_{CWCE}$.
2. Paradigma Supervised Contrastive Learning (SupCon): Terdiri dari tahap pre-training representasi laten menggunakan SupCon loss ($\tau = 0,07$), dilanjutkan tahap linear evaluation / fine-tuning menggunakan classifier linier 7 kelas.

Untuk menjamin validitas dan mencegah kebocoran data, penelitian ini tidak menggunakan k-fold cross validation acak, melainkan mengeksekusi pelatihan secara ketat pada partisi baku terisolasi lesi DermaMNIST-C dengan protokol penguncian benih acak (*multi-seed*: seed 42, 123, 2026), di mana seluruh metrik dilaporkan dalam format nilai rata-rata dan deviasi standar (*mean* ± *std*).

3.2.7 Evaluasi Model

Model yang telah dilatih dievaluasi secara komprehensif pada himpunan data uji baku (1.227 citra) berdasarkan tiga pilar metrik:

1. Performa Diagnostik Multikelas: Balanced Accuracy, Macro Precision,

Macro Recall, Macro F1-Score, dan Multiclass Matthews Correlation Coefficient (MCC).

2. Reliabilitas Kalibrasi Prediksi: Expected Calibration Error (ECE) dengan 10 bin interval kepercayaan serta Brier Score.
3. Efisiensi Komputasi Hardware: Jumlah parameter, GFLOPs, latensi inferensi per sampel pada batch=1 (ms), throughput (citra/detik), dan alokasi memori VRAM puncak.

3.3 Alat dan Bahan Tugas Akhir

Bagian ini merinci spesifikasi perangkat keras, perangkat lunak, dan bahan data yang digunakan dalam pelaksanaan eksperimen.

3.3.1 Alat

Alat yang digunakan dalam penelitian ini meliputi:

1. Perangkat Keras Komputasi (Server GPU): Unit pemroses grafis NVIDIA Tesla T4 dengan kapasitas memori 16 GB GDDR6 VRAM berbasis arsitektur Turing (*Compute Capability* 7.5) pada lingkungan komputasi cloud (Google Colab / Kaggle).
2. Sistem Operasi Linux Ubuntu (cloud instance) / Arch Linux (workstation lokal).
3. Laptop
4. Python 3.10.
5. Pustaka perangkat lunak: PyTorch 2.x, Torchvision, CUDA Toolkit 12.x, pustaka resmi `mamba-ssm`, `causal-conv1d`, NumPy, Pandas, Scikit-learn, Matplotlib, Seaborn, dan Timm.

3.3.2 Bahan Penelitian

Bahan yang digunakan dalam penelitian ini adalah:

1. Dataset DermaMNIST-C: Berkas format arsip NPZ resmi yang memuat pasangan matriks citra $224 \times 224 \times 3$ dan label kategori medis 7 kelas,

terbagi baku atas 8.215 citra latih, 573 citra validasi, dan 1.227 citra uji [5]. Seluruh citra telah terbebas dari kebocoran data melalui penerapan pemisahan terisolasi di tingkat lesi (*lesion-level disjoint split*) dan interpolasi *bicubic* langsung dari citra resolusi tinggi HAM10000.

3.3.3 Kelayakan Eksperimen dan Anggaran Komputasi

Guna memastikan bahwa seluruh rangkaian pengujian dapat diselesaikan secara realistis dalam batasan kuota lingkungan komputasi cloud (Google Colab / Kaggle yang menyediakan alokasi GPU sekitar 30 jam per minggu), anggaran komputasi dihitung secara terperinci:

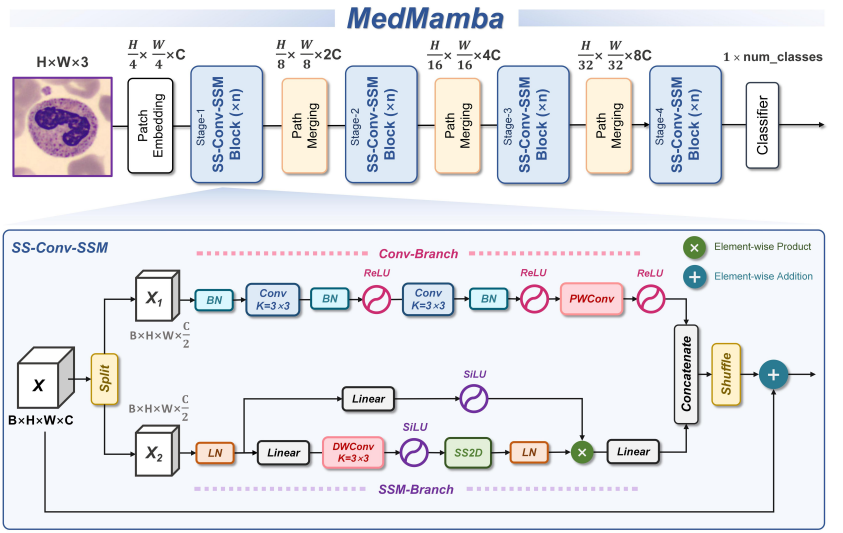
1. **Total Beban Pelatihan**: Skenario pengujian faktorial 3×2 ditambah 3 baseline keluarga ResNet dieksekusi dengan $N = 3$ benih acak independen, menghasilkan total 27 kali pelatihan penuh:
    - Paradigma Supervised (3 model MedMamba + 3 model ResNet = 6 model $\times$ 3 seed = 18 run): 50 epoch per run (total 900 epoch).
    - Paradigma SupCon (3 model MedMamba $\times$ 3 seed = 9 run): Tahap 1 (50 epoch) + Tahap 2 (30 epoch) = 80 epoch per run (total 720 epoch).
    - Total kumulatif pelatihan: 27 run mencakup 1.620 epoch.
2. **Waktu Eksekusi dan Throughput**: Pada GPU NVIDIA Tesla T4 (16 GB GDDR6), estimasi waktu pelatihan per epoch untuk model terbesar (MedMamba-B, batch size 32 atau 64 view pada SupCon) dengan akselerasi FP16 berkisar antara $45 - 55$ detik, sedangkan varian ResNet berjalan lebih cepat ($\approx 20 - 30$ detik per epoch). Total waktu komputasi murni untuk seluruh 27 run diestimasikan sebesar $\approx 22 - 24$ jam GPU.
3. **Strategi Eksekusi**: Eksperimen dijalankan secara modular menggunakan mekanisme penyimpanan checkpoint berkala (*checkpointing*), sehingga proses pelatihan dapat dilanjutkan secara transparan antar-sesi tanpa risiko kehilangan progres akibat batasan durasi sesi (*session timeout*).

3.4 Metode Pengembangan

Bagian ini menguraikan spesifikasi teknis arsitektur model MedMamba, rancangan protokol kedua paradigma pelatihan, serta mekanisme pembobotan kelas.

3.4.1 Spesifikasi Arsitektur Model MedMamba

Arsitektur MedMamba [11] dibangun atas susunan hierarkis 4 stage pemrosesan dengan lapisan pereduksi resolusi spasial (*Patch Embedding* ukuran 4×4 dan *Patch Merging*). Setiap stage terdiri dari serangkaian blok residual **SS-Conv-SSM** yang mengintegrasikan konvolusi grup 2D dengan *Visual State Space Module* (VSSM) berbasis *Cross-Scan Module* 4-arah ber-kompleksitas linear $O(N)$ [20]. Arsitektur model MedMamba secara rinci diilustrasikan pada Gambar 3.2.



Gambar 3.2 Arsitektur Model MedMamba [11]

Konfigurasi teknis dari ketiga varian MedMamba yang dievaluasi dirinci sebagai berikut:

1. **MedMamba-T (*Tiny*)**:
    - Kedalaman blok per stage: `depths = [2, 2, 4, 2]`
    - Dimensi kanal per stage: `dims = [96, 192, 384, 768]`
    - Jumlah parameter terparameterisasi (7 kelas): ∼14,5 Juta parameter.
2. **MedMamba-S (*Small*)** (Model Fokus):
    - Kedalaman blok per stage: `depths = [2, 2, 8, 2]`
    - Dimensi kanal per stage: `dims = [96, 192, 384, 768]`
    - Jumlah parameter terparameterisasi (7 kelas): ∼22,8 Juta parameter.
3. **MedMamba-B (*Base*)**:
    - Kedalaman blok per stage: `depths = [2, 2, 12, 2]`
    - Dimensi kanal per stage: `dims = [128, 256, 512, 1024]`
    - Jumlah parameter terparameterisasi (7 kelas): ∼47,1 Juta parameter.

Sebagai pembanding dasar arsitektur CNN konvensional yang seimbang secara kapasitas, digunakan tiga varian dari keluarga ResNet: ResNet-18 (∼11,2 Juta parameter) untuk membandingkan MedMamba-T, ResNet-50 (∼23,5 Juta parameter) untuk MedMamba-S, dan ResNet-101 (∼44,5 Juta parameter) untuk MedMamba-B. Seluruh model skala MedMamba dilatih sepenuhnya dari inisialisasi bobot acak (*random initialization* / *from scratch*) untuk memastikan perbandingan kapasitas yang adil. Lapisan konvolusi diinisialisasi menggunakan metode Kaiming Normal, dan proyeksi linier standar menggunakan Truncated Normal ($\sigma = 0,02$), dengan mempertahankan inisialisasi matematis khusus bawaan Mamba pada parameter *Selective Scan* (proyeksi $\mathbf{\Delta}$, matriks transisi keadaan kontinu $\mathbf{A}$, dan vektor bias $\mathbf{D}$) [10].

3.4.2 Implementasi Paradigma Pelatihan

Pelatihan model dikembangkan melalui dua paradigma utama:

3.4.2.1 Supervised Learning

Model klasifikasi dilatih secara *end-to-end* dari citra input menuju klasifikasi 7 kelas:

- Loss Function: *Class-Weighted Cross-Entropy Loss* ($\mathcal{L}_{CWCE}$).
- Optimizer: AdamW dengan *weight decay* 1×10^{-4} dan *initial learning rate* $\eta = 1 \times 10^{-4}$.
- Learning Rate Scheduler: *Cosine Annealing Learning Rate Scheduler* dengan $T_{max} = 50$ epoch dan $\eta_{min} = 1 \times 10^{-6}$.
- Batch Size: 32 sampel citra per batch.
- Presisi Pelatihan: *Automatic Mixed Precision* (AMP) FP16 untuk mempercepat komputasi dan menghemat penggunaan VRAM.

3.4.2.2 Supervised Contrastive Learning (SupCon)

Paradigma SupCon dieksekusi melalui protokol dua tahap terstruktur:

- **Tahap 1 (Contrastive Pre-training)**:
  1. Pasang *Projection Head* non-linier 2-layer MLP di atas backbone MedMamba: Lapisan Linier ($d_{in} \rightarrow 512$) $\rightarrow$ ReLU $\rightarrow$ Lapisan Linier ($512 \rightarrow 128$) $\rightarrow$ Normalisasi L2 ($\|z\|_2 = 1$).
  2. Untuk setiap batch berukuran $N = 32$, hasilkan $2N = 64$ tampilan teraugmentasi secara stokastik.
  3. Hitung fungsi kerugian SupCon dengan parameter temperatur $\tau = 0,07$:

$$\mathcal{L}_{SupCon} = \sum_{i=1}^{2N} \frac{-1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(z_i \cdot z_p / 0,07)}{\sum_{a \in A(i)} \exp(z_i \cdot z_a / 0,07)} \quad \text{(Rumus 3.2)}$$

  4. Latih backbone dan projection head selama 50 epoch menggunakan AdamW ($\eta = 1 \times 10^{-4}$).
- **Tahap 2 (Linear Classification Training)**:

1. Lepaskan *Projection Head*, pasang lapisan klasifikasi linier (*Linear Classifier*) berdimensi output 7 kelas langsung di atas fitur representasi backbone ($d_{in} \rightarrow 7$).
2. Latih lapisan klasifikasi menggunakan fungsi kerugian $\mathcal{L}_{CWCE}$ selama 30 epoch. Pada evaluasi primer, backbone dibekukan (*linear probing*) untuk mengisolasi kualitas murni representasi ruang laten; pada evaluasi sekunder, seluruh jaringan di-fine-tune dengan laju belajar rendah ($\eta = 1 \times 10^{-5}$).

3.5 Rancangan Pengujian dan Skema Eksperimen

Rancangan eksperimen disusun ke dalam tiga skenario utama berdesain faktorial 3×2 (3 Skala Parameter $\times$ 2 Paradigma Pelatihan) ditambah 3 model baseline keluarga ResNet berparameter setara guna menjawab seluruh rumusan masalah secara komprehensif:

3.5.1 Skenario 1: Evaluasi Skalabilitas MedMamba pada Paradigma Supervised Learning

Skenario ini mengevaluasi ketiga skala MedMamba (Tiny, Small, Base) yang dilatih sepenuhnya dari awal (*scratch*) menggunakan paradigma Supervised Learning terbobot ($\mathcal{L}_{CWCE}$). Model keluarga ResNet (ResNet-18, ResNet-50, dan ResNet-101) diikutsertakan sebagai baseline pembanding konvensional berpasangan pada masing-masing tingkatan skala (Tiny, Small, Base). Eksperimen ini memetakan korelasi antara penambahan kapasitas parameter model terhadap peningkatan performa metrik klinis (Balanced Accuracy, Macro-F1, Multiclass MCC) dan biaya komputasi fisik (GFLOPs, latensi inferensi, konsumsi VRAM puncak).

3.5.2 Skenario 2: Evaluasi Skalabilitas MedMamba pada Paradigma Supervised Contrastive Learning

Skenario ini mengevaluasi ketiga skala MedMamba (Tiny, Small, Base dari *scratch*) di bawah paradigma SupCon dua tahap. Pengujian ini bertujuan untuk membuktikan secara empiris apakah peningkatan skala parameter SSM berkorelasi lurus dengan kualitas separabilitas representasi visual kelas minoritas pada ruang manifold laten di bawah protokol pelatihan kontrastif terawasi.

3.5.3 Skenario 3: Analisis Komparatif Efek Interaksi Paradigma dan Skalabilitas (Paradigma $\times$ Skala)

Skenario ini melakukan analisis komparatif faktorial antara Skenario 1 dan Skenario 2 guna menguji hipotesis interaksi antara skala kapasitas model dan paradigma pembelajaran:

1. **Formulasi Hipotesis Interaksi**:
    - *Hipotesis Nol* (H_0): Peningkatan skala parameter MedMamba (dari Tiny ke Base) menghasilkan pola perubahan performa diagnostik pada kelas minoritas (*Balanced Accuracy* dan *Macro-F1*) yang sejajar antara paradigma *Supervised Learning* dan *Supervised Contrastive Learning* (tidak terdapat efek interaksi skala $\times$ paradigma).
    - *Hipotesis Alternatif* (H_1): Peningkatan skala parameter MedMamba berinteraksi secara positif dengan paradigma SupCon, menghasilkan amplifikasi separabilitas ruang laten dan metrik keadilan prediksi kelas minoritas yang lebih tinggi secara signifikan dibandingkan peningkatan skala pada Supervised Learning langsung, karena representasi manifold laten SupCon mencegah penekanan fitur minoritas oleh mayoritas pada model berkapasitas besar.
2. **Kuantifikasi dan Visualisasi Ruang Laten**: Mengukur keterpisahan klaster representasi fitur lapisan akhir secara kuantitatif melalui k-NN Classification Accuracy ($k = 5$) dan *Silhouette Score*, serta didukung

visualisasi reduksi dimensi t-SNE (*t-Distributed Stochastic Neighbor Embedding*) untuk membandingkan kerapatan intra-kelas dan separabilitas margin antar-kelas antara kedua paradigma.

3. **Analisis Reliabilitas Kalibrasi Prediksi**: Mengukur nilai *Expected Calibration Error* (ECE) dengan 10 interval bin dan memplot *Reliability Diagram* untuk menguji apakah pemisahan representasi kontrastif menghasilkan estimasi probabilitas prediksi yang lebih terkalibrasi secara klinis dibandingkan Cross-Entropy langsung.
4. **Analisis Trade-Off Komputasi**: Membandingkan total waktu pelatihan, throughput pemrosesan citra, dan alokasi memori fisik antar kedua paradigma pada lingkungan komputasi GPU Tesla T4.

3.6 Metrik Evaluasi dan Protokol Validasi

Seluruh model pada setiap skenario dievaluasi pada himpunan data uji baku (1.227 citra) menggunakan protokol validasi ketat:

3.6.1 Kriteria Pemilihan Model (Model Selection) dan Protokol Konvergensi

Untuk menghindari anomali penghentian dini acak (*premature random stopping*) yang rentan dipicu oleh fluktuasi stokastik sampel validasi minoritas yang sangat kecil ($N_{val,df} = 7$ dan $N_{val,vasc} = 8$), serta menjamin penjadwal laju belajar Cosine Annealing menyelesaikan kurva peluruhan hingga mencapai laju belajar minimum ($\eta_{min} = 1 \times 10^{-6}$), seluruh model dilatih dengan **alokasi anggaran 50 epoch tetap (*fixed budget of 50 epochs*)**.

Protokol penentuan model checkpoint terbaik (*Model Selection*) yang dievaluasi ke data uji didefinisikan secara ketat sesuai karakteristik masing-masing paradigma:

1. **Paradigma Supervised Learning**: Checkpoint model optimal dipilih berdasarkan **nilai kerugian validasi terbobot minimum ($\mathcal{L}_{CWCE}^{val}$)**, yang

dikonfirmasi kestabilan tren Macro-F1 validasinya pada rentang 10 epoch terakhir guna mencegah pemilihan model akibat lonjakan acak sesaat (*stochastic spike*).

2. **Paradigma Supervised Contrastive Learning (SupCon)**:
   - *Tahap 1 (Contrastive Pre-training, 50 epoch)*: Mengingat belum terdapat lapisan klasifikasi label pada tahap ini, checkpoint representasi encoder terbaik dipilih berdasarkan **nilai kerugian validasi SupCon minimum** ($\mathcal{L}_{SupCon}^{val}$) pada data validasi.
   - *Tahap 2 (Linear Probing / Fine-tuning, 30 epoch)*: Checkpoint klasifikasi akhir yang diuji pada data uji dipilih berdasarkan **skor Macro-F1 validasi tertinggi**.

3.6.2 Metrik Performa Diagnostik Multikelas

Kinerja diagnostik klinis dihitung berdasarkan matriks kontingensi multikelas (*Confusion Matrix*) $\mathbf{M} \in \mathbb{R}^{K \times K}$ menggunakan metrik yang tidak terdistorsi oleh populasi kelas mayoritas:

1. **Balanced Accuracy (Macro Recall)**: Rata-rata sensitivitas di seluruh $K = 7$ kelas diagnosis.
2. **Macro Precision**: Rata-rata ketepatan prediksi positif di seluruh $K = 7$ kelas diagnosis.
3. **Macro F1-Score**: Rata-rata aritmatika unweighted dari skor F1 per kelas:

$$\text{Macro-F1} = \frac{1}{K}\sum_{k=1}^{K} \text{F1}_k = \frac{1}{K}\sum_{k=1}^{K} \frac{2 \cdot \text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k} \quad \text{(Rumus 3.3)}$$

4. **Multiclass Matthews Correlation Coefficient (MCC)**: Koefisien korelasi multikelas menurut formulasi Gorodkin (2004) [22] yang memperhitungkan seluruh elemen matriks konfusi dan terbukti paling objektif untuk dataset dengan ketidakseimbangan kelas ekstrem.

3.6.3 Kuantifikasi Separabilitas Ruang Laten

Untuk melengkapi visualisasi kualitatif t-SNE, separabilitas representasi fitur laten pada lapisan sebelum klasifikasi diukur secara objektif melalui dua metrik kuantitatif:

1. **k-Nearest Neighbors (k-NN) Accuracy**: Evaluasi akurasi prediksi label kelas menggunakan algoritma k-NN ($k = 5$) langsung pada vektor fitur laten tanpa pelatihan parameter tambahan.
2. **Silhouette Score**: Mengukur rasio antara jarak intra-klaster rata-rata (a) dan jarak antar-klaster terdekat (b) pada rentang $[-1, +1]$:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \qquad \text{(Rumus 3.4)}$$

di mana skor yang mendekati +1 membuktikan bahwa klaster representasi kelas terpisah secara kompak dan tegas.

3.6.4 Metrik Reliabilitas Kalibrasi Prediksi

Keandalan probabilitas keluaran model diukur melalui dua pilar metrik:

1. **Expected Calibration Error (ECE)**: Rata-rata selisih absolut terbobot antara tingkat kepercayaan prediksi (*confidence score*) dengan akurasi aktual sampel yang dikelompokkan ke dalam 10 interval bin ($M = 10$) [23]:

$$\text{ECE} = \sum_{m=1}^{M} \frac{|B_m|}{N_{test}} \left|\text{acc}(B_m) - \text{conf}(B_m)\right| \qquad \text{(Rumus 3.5)}$$

2. **Brier Score**: Kesalahan kuadrat rata-rata antara vektor probabilitas keluaran model dengan representasi biner *one-hot* label ground-truth [24]:

$$\text{Brier Score} = \frac{1}{N_{test}} \sum_{i=1}^{N_{test}} \sum_{k=1}^{K} \left(\hat{p}_{i,k} - y_{i,k}\right)^2 \qquad \text{(Rumus 3.6)}$$

3.6.5 Metrik Efisiensi Komputasi Hardware dan Protokol Profiling

Pengukuran efisiensi komputasi fisik dilakukan dengan protokol ketat:

1. **Jumlah Parameter (M)**: Dihitung secara eksak dari total parameter terbobot PyTorch menggunakan fungsi `sum(p.numel() for p in model.parameters())`.
2. **GFLOPs**: Dihitung berdasarkan total operasi titik kambang (*Floating-Point Operations*) teoritis untuk pemrosesan satu citra masukan $1 \times 3 \times 224 \times 224$. Mengingat pustaka profiler standar (seperti `fvcore` atau `thop`) tidak mampu melacak eksekusi kernel kustom CUDA C++/Triton pada operasi sekuensial rekursif Mamba (*selective scan recurrence*), kalkulasi komputasi MedMamba mengintegrasikan penghitungan FLOPs teoritis resmi modul *Visual State Space* (VSSM) dengan formula eksplisit operasi per arah pindaian pada modul *Cross-Scan* (CSM 4-arah) [11], [20]:

$$\text{FLOPs}_{\text{CSM}} = 4 \times (9 \cdot B \cdot L \cdot D \cdot N) = 36 \cdot B \cdot L \cdot D \cdot N \quad \text{(Rumus 3.7)}$$

   Total FLOPs dari seluruh tahapan jaringan (konvolusi stem, blok SS-Conv-SSM, downsampling, dan classifier head) kemudian dinormalisasi ke dalam satuan GFLOPs:

$$\text{GFLOPs} = \frac{\text{Total FLOPs}}{10^9} \quad \text{(Rumus 3.8)}$$

3. **Latensi Inferensi Batch-1 (ms)**: Waktu eksekusi inferensi pada citra tunggal ($1 \times 3 \times 224 \times 224$) menggunakan GPU NVIDIA Tesla T4. Pengukuran diawali dengan 10 iterasi pemanasan (*warm-up runs*) untuk menstabilkan cache CUDA, dilanjutkan dengan 100 iterasi pengujian yang disinkronkan secara eksplisit menggunakan `torch.cuda.synchronize()`, lalu dilaporkan nilai median dan rentang interkuartil (*Interquartile Range* / IQR) untuk menangkap dispersi tanpa

terpengaruh pencilan:

$$\text{IQR} = Q_3 - Q_1 \qquad \text{(Rumus 3.9)}$$

4. **Throughput**: Jumlah citra yang berhasil diproses per satuan waktu pada ukuran batch penuh saat inferensi:

$$\text{Throughput} = \frac{N_{\text{batch}}}{T_{\text{inferensi}}} \quad \text{(citra/detik)} \qquad \text{(Rumus 3.10)}$$

5. **Konsumsi Memori VRAM Puncak (MB)**: Alokasi memori GPU maksimum selama proses propagasi maju dan mundur yang dicatat menggunakan fungsi internal `torch.cuda.max_memory_allocated()`.

3.6.6 Protokol Validasi Statistik dan Estimasi Ketidakpastian Uji

Mengingat partisi uji baku memiliki ukuran terbatas pada kelas minoritas (`df` = 14 sampel dan `vasc` = 19 sampel), evaluasi memisahkan dua sumber variabilitas statistik secara eksplisit:

1. **Variabilitas Optimasi (Multi-Seed Independent Replication)**: Setiap konfigurasi model dilatih menggunakan $S = 3$ benih acak independen (Seed 42, 123, dan 2026) untuk merekam variabilitas stokastik proses inisialisasi bobot dan pengacakan urutan mini-batch. Deviasi standar sampel antar-seed dihitung menurut:

$$\sigma_{seed} = \sqrt{\frac{1}{S-1}\sum_{s=1}^{S}(\theta_s - \bar{\theta})^2} \qquad \text{(Rumus 3.11)}$$

di mana $\bar{\theta} = \frac{1}{S}\sum_{s=1}^{S}\theta_s$ adalah nilai rata-rata estimasi performa antar-seed.

2. **Ketidakpastian Sampling Data Uji (Non-Parametric Bootstrap 95% Confidence Interval)**: Untuk mengukur ketidakpastian sampling empiris pada himpunan data uji baku ($N_{test} = 1.227$), dilakukan prosedur *bootstrap resampling* dengan pengembalian (*with replacement*) sebanyak

B = 1.000 iterasi pada prediksi model. Rentang interval kepercayaan 95% dilaporkan dalam format [95% CI: batas bawah – batas atas] yang dihitung dari persentil ke-2,5 dan persentil ke-97,5 distribusi bootstrap.

Format pelaporan akhir untuk seluruh metrik utama adalah:

$$\bar{\theta} \pm \sigma_{seed} \quad [95\%\ \text{CI}] \qquad \text{(Rumus 3.12)}$$

sehingga penguji dan pembaca dapat membedakan secara tegas antara variasi kestabilan pelatihan (σ_{seed}) dan batas ketidakpastian sampling data uji ([95% CI]).

DAFTAR PUSTAKA

[1] Andre Esteva et al. “Dermatologist-level classification of skin cancer with deep neural networks”. *Nature* 542.7639 (2017), pp. 115–118.

[2] Philipp Tschandl, Cliff Rosendahl, and Harald Kittler. “The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions”. *Scientific Data* 5.1 (2018), p. 180161.

[3] Geert Litjens et al. “A survey on deep learning in medical image analysis”. *Medical Image Analysis* 42 (2017), pp. 60–88.

[4] Mabrouka Salmi et al. “Handling imbalanced medical datasets: review of a decade of research”. *Artificial Intelligence Review* 57.10 (2024), p. 273.

[5] Kumar Abhishek, Aditi Jain, and Ghassan Hamarneh. “Investigating the quality of DermaMNIST and Fitzpatrick17k dermatological image datasets”. *Scientific Data* 12.1 (2025), p. 196.

[6] Nerma Kadric, Amila Akagic, and Medina Kapo. “Improving Diagnostic Accuracy of Pigmented Skin Lesions With CNNs: An Application on the DermaMNIST Dataset”. *arXiv preprint arXiv:2507.12961* (2025). arXiv: 2507.12961 [eess.IV].

[7] Arkan Hariz. “Analisis Performa Arsitektur ResNet-18 dan ResNet-50 dengan Penerapan Augmentasi Data Kelas Minoritas pada Dataset DermaMNIST”. Bachelor’s Thesis. Lampung, Indonesia: Institut Teknologi Sumatera, 2026.

[8] Alexey Dosovitskiy et al. “An image is worth 16x16 words: Transformers for image recognition at scale”. *International Conference on Learning Representations (ICLR)*. 2021.

[9] Aidar Amangeldi et al. “CNN and ViT Efficiency Study on Tiny ImageNet and DermaMNIST Datasets”. *arXiv preprint arXiv:2505.08259* (2025). arXiv: 2505.08259 [cs.CV].

[10] Albert Gu and Tri Dao. “Mamba: Linear-Time Sequence Modeling with Selective State Spaces”. *arXiv preprint arXiv:2312.00752* (2024). arXiv: 2312.00752 [cs.LG].

[11] Yubiao Yue and Zhenzhang Li. “MedMamba: Vision Mamba for Medical Image Classification”. *arXiv preprint arXiv:2403.03849* (2024). arXiv: 2403.03849 [eess.IV].

[12] Ruhollah Aalishah, Mahdi Navardi, and Tinoosh Mohsenin. “MedMambaLite: Hardware-Aware Mamba for Medical Image Classification”. *arXiv preprint arXiv:2508.05049* (2025). arXiv: 2508.05049 [cs.CV].

[13] Prannay Khosla et al. “Supervised Contrastive Learning”. *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 33. 2020, pp. 18661–18673.

[14] Ze Liu et al. “Swin transformer: Hierarchical vision transformer using shifted windows”. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 10012–10022.

[15] Keyu Chen, Di Zhuang, and J Morris Chang. “SuperCon: Supervised Contrastive Learning for Imbalanced Skin Lesion Classification”. *arXiv preprint arXiv:2202.05685* (2022).

[16] Jiancheng Yang et al. “MedMNIST v2–A large-scale lightweight benchmark for 2D and 3D biomedical image classification”. *Scientific Data* 10.1 (2023), p. 41.

[17] Clay J. Cockerell. “Histopathology of incipient intraepidermal squamous cell carcinoma (“actinic keratosis”)”. *Journal of the American Academy of Dermatology* 42.1 (2000), S11–S17.

[18] Yin Cui et al. “Class-Balanced Loss Based on Effective Number of Samples”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2019, pp. 9268–9277.

[19] Kaiming He et al. “Deep residual learning for image recognition”. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, pp. 770–778.

[20] Yue Liu et al. “VMamba: Visual State Space Model”. *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 37. 2024.

[21] Margherita Grandini, Enrico Bagli, and Giorgio Visani. “Metrics for Multi-Class Classification: an Overview”. *arXiv preprint arXiv:2008.05756* (2020). arXiv: 2008.05756 [stat.ML].

[22] Jan Gorodkin. “Comparing two K-category assignments by a K-category correlation coefficient”. *Computational Biology and Chemistry* 28.5-6 (2004), pp. 367–374.

[23] Chuan Guo et al. “On calibration of modern neural networks”. *Proceedings of the 34th International Conference on Machine Learning (ICML)*. 2017, pp. 1321–1330.

[24] Glenn W. Brier. “Verification of forecasts expressed in terms of probability”. *Monthly Weather Review* 78.1 (1950), pp. 1–3.

LAMPIRAN

A Karakteristik dan Partisi Dataset DermaMNIST-C

Dataset DermaMNIST-C [5] yang digunakan dalam penelitian ini merupakan turunan langsung dari HAM10000 dengan partisi baku terisolasi lesi (*lesion-level split*) beresolusi $224 \times 224 \times 3$. Distribusi frekuensi sampel per kelas pada setiap partisi disajikan untuk melengkapi analisis ketidakseimbangan data.

B Konfigurasi Detail Arsitektur MedMamba dan Keluarga ResNet

Rincian dimensi kanal (*dims*), jumlah blok berulang (*depths*), dan mekanisme pindaian spasial empat arah (*Cross-Scan Module*) pada setiap tingkatan (*stage*) hierarki MedMamba-Tiny, MedMamba-Small, dan MedMamba-Base, serta arsitektur baseline pembanding keluarga ResNet (ResNet-18, ResNet-50, dan ResNet-101).

C Lingkungan Perangkat Lunak dan Reproduksibilitas Eksperimen

Rincian dependensi pustaka Python, CUDA, pustaka `mamba-ssm`, serta konfigurasi benih acak (*seed* 42, 123, 2026) guna menjamin reproduksibilitas penuh seluruh skenario eksperimen.