STUDI KOMPARATIF EFEK PARADIGMA PELATIHAN TERHADAP SKALABILITAS ARSITEKTUR MEDMAMBA UNTUK KLASIFIKASI CITRA PENYAKIT KULIT

TUGAS AKHIR

Muhammad Royhan Alfitra

123140146



PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
LAMPUNG SELATAN
2026

DAFTAR ISI

DAFTAR ISI ..... **ii**

DAFTAR TABEL ..... **iv**

DAFTAR GAMBAR ..... **v**

DAFTAR RUMUS ..... **vi**

DAFTAR KODE ..... **vii**

BAB I PENDAHULUAN **1**

1.1 Latar Belakang 1

1.2 Rumusan Masalah 3

1.3 Tujuan Penelitian 3

1.4 Batasan Masalah 4

1.5 Manfaat Penelitian 4

1.6 Sistematika Penulisan 5

BAB II TINJAUAN PUSTAKA **6**

2.1 Tinjauan Pustaka 6

2.2 Dasar Teori 11

2.2.1 DermaMNIST-C 11

2.2.1.1 Actinic Keratoses and Intraepidhelial Carcinoma (`akiec`) 12

2.2.1.2 Basal Cell Carcinoma (`bcc`) 12

2.2.1.3 Benign Keratosis-Like Lesions (`bkl`) 12

2.2.1.4 Dermatofibroma (`df`) 13

2.2.1.5 Melanoma (`mel`) 13

2.2.1.6 Melanocytic Nevi (`nv`) 13

2.2.1.7 Vascular Lesions (`vasc`) 14

2.2.2 Fitzpatrick17k-C 14
2.2.3 *Imbalanced Data* 15
2.2.4 Arsitektur Model: Dari CNN/ViT ke State Space Models (MedMamba) 15
2.2.4.1 Prinsip Dasar State Space Models (SSM) dan Mamba 16
2.2.4.2 Modul Visual State Space Module (VSSM) dan Skalabilitas MedMamba 16
2.2.5 Paradigma Pelatihan: Supervised vs. Contrastive Learning 17
2.2.6 Metrik Evaluasi, Kalibrasi, dan Efisiensi Perangkat Keras . 17
2.2.6.1 Metrik Kinerja Klasifikasi Multikelas 18
2.2.6.2 Metrik Reliabilitas Kalibrasi Prediksi 18
2.2.7 Metrik Efisiensi Komputasi Hardware 18

BAB III METODE PENELITIAN 19

3.1 Alur Penelitian 19
3.2 Penjabaran Langkah Penelitian 19
3.2.1 Identifikasi Masalah 19
3.2.2 Studi Literatur 20
3.2.3 Akuisisi Dataset 21
3.2.4 Preprocessing Data 21
3.2.5 Penanganan Imbalanced Data dan Augmentasi 22
3.2.6 Perancangan Model dan Skenario Pelatihan 22
3.2.7 Evaluasi Model 23
3.3 Alat dan Bahan Tugas Akhir 23
3.3.1 Alat 23
3.3.2 Bahan Penelitian 24
3.4 Metode Pengembangan 24
3.4.1 Arsitektur Model MedMamba 25
3.4.2 Supervised vs. Contrastive Learning 25

3.4.3 Strategi Mitigasi Data Tak Seimbang 26
3.5 Rancangan Pengujian dan Skema Eksperimen 26
3.6 Metrik Evaluasi 27
3.6.1 Metrik Performa Klasifikasi Multikelas 27
3.6.2 Metrik Reliabilitas Kalibrasi Prediksi 28
3.6.3 Metrik Efisiensi Komputasi Hardware 28

DAFTAR PUSTAKA **29**

LAMPIRAN **33**
A Dataset 33
B Hasil Wawancara 33
C Rincian Kasus Uji 33

DAFTAR TABEL

Tabel 2.1 Literasi Penelitian Terdahulu 9

DAFTAR GAMBAR

Gambar 3.1 Alur Penelitian 19

DAFTAR RUMUS

DAFTAR KODE

BAB I
PENDAHULUAN

1.1 Latar Belakang

Diagnosis penyakit kulit berbasis citra medis kini bertransisi secara signifikan ke arah paradigma ”Deployment-First Medical AI”, di mana efisiensi komputasi dan kecepatan inferensi pada perangkat edge menjadi prioritas utama selain akurasi klinis [1], [2]. Di fasilitas pelayanan kesehatan dengan infrastruktur komputasi terbatas, ketersediaan model kecerdasan buatan yang ringan dan andal sangat krusial untuk membantu klinisi dalam melakukan deteksi dini lesi kulit [3].

Dalam implementasinya, klasifikasi penyakit kulit berbasis Deep Learning dihadapkan pada dua tantangan utama: ketidakseimbangan kelas (class imbalance) yang ekstrem dan keterbatasan sumber daya komputasi [4], [5]. Penelitian terdahulu pada dataset DermaMNIST menggunakan model konvensional seperti ResNet-18 dan ResNet-50 [6] menunjukkan kecenderungan prediksi yang sangat terbias pada kelas mayoritas (Melanocytic Nevi mendominasi hingga ~67% data), sehingga gagal mengenali kelas-kelas penyakit langka secara akurat [7]. Di sisi lain, meskipun arsitektur Vision Transformer (ViT) [8], [9] menawarkan keunggulan dalam menangkap konteks spasial global, kompleksitas komputasi kuadratiknya $O(N^2)$ terhadap panjang sekuens/resolusi gambar sangat membebani memori VRAM dan daya komputasi perangkat lunak medis [10].

Sebagai terobosan mutakhir, muncul arsitektur berbasis State Space Models (SSM) / Mamba yang menggabungkan lapisan konvolusi untuk fitur lokal dengan selective scan module untuk pemrosesan konteks global berkompleksitas linear $O(N)$ [11]. Salah satu arsitektur pionir di domain medis adalah MedMamba [12], yang hadir dalam berbagai skala parameter meliputi

MedMamba-T (Tiny, ~14,5M parameter), MedMamba-S (Small, ~22,8M parameter), dan MedMamba-B (Base, ~47,1M parameter). Kehadiran variasi skala ini memungkinkan eksplorasi trade-off antara kapasitas representasi fitur dan efisiensi komputasi [13].

Namun demikian, validitas ilmiah dari pengembangan model AI medis sangat bergantung pada integritas data yang digunakan. Investigasi kualitas data oleh Abhishek et al. (2025) mengungkapkan ditemukannya kebocoran data (*data leakage*) sebesar **13,47%** (1.006 dari 7.470 lesi unik) pada dataset DermaMNIST murni akibat pemisahan data yang tidak terisolasi di tingkat pasien/lesi (*lesion-level split*) [14], [15]. Kebocoran ini menyebabkan performa benchmark terinflasi secara semu karena model sekadar ”menghafal” lesi pasien yang sama di folder pengujian. Masalah serupa berupa duplikasi dan ketidaksesuaian label juga ditemukan pada dataset Fitzpatrick17k [16]. Oleh karena itu, penggunaan versi dataset terkoreksi (**DermaMNIST-C** dan **Fitzpatrick17k-C**) yang bebas dari kebocoran data sangat mutlak diperlukan.

Untuk membangun model diagnostik yang tangguh (*robust*) [17], pengujian tidak hanya perlu dilakukan secara *in-dataset*, melainkan juga melalui **evaluasi lintas-dataset (*cross-dataset generalization*)**. Selain itu, paradigma pelatihan juga berkembang dari *Supervised Learning* langsung menuju *Contrastive Learning* untuk mempelajari representasi visual lesi yang lebih kaya tanpa terdistorsi oleh bias label mayoritas [18].

Berdasarkan urgensi tersebut, penelitian ini dirancang untuk melakukan evaluasi komprehensif terhadap **skalabilitas dan generalisasi arsitektur MedMamba (MedMamba-T, MedMamba-S, dan MedMamba-B)** pada dataset terkoreksi (DermaMNIST-C dan Fitzpatrick17k-C). Penelitian ini membandingkan skenario pelatihan *Supervised* vs *Contrastive*, menguji dampak *data leakage* secara eksperimental, serta mengeksekusi **studi ablasi mendalam pada MedMamba-S** sebagai model fokus utama.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana efisiensi komputasi, performa klasifikasi, dan skalabilitas dari keluarga arsitektur MedMamba (MedMamba-T, MedMamba-S, dan MedMamba-B) dalam mengklasifikasikan citra penyakit kulit dengan ketidakseimbangan kelas yang ekstrem?
2. Sejauh mana perbedaan efektivitas skenario pelatihan Supervised Learning dibandingkan Contrastive Learning dalam mengekstrak representasi fitur visual lesi kulit yang diskriminatif?
3. Bagaimana tingkat keandalan generalisasi lintas-dataset (cross-dataset generalization) dari model MedMamba ketika dilatih dan diuji secara silang antara DermaMNIST-C dan Fitzpatrick17k-C, serta seberapa besar dampak kebocoran data (data leakage) yang terjadi pada dataset DermaMNIST murni (origin)?
4. Sejauh mana komponen-komponen utama pada arsitektur fokus MedMamba-S (skema fungsi kerugian/loss, strategi inisialisasi bobot pretrained, dan augmentasi data) berkontribusi terhadap peningkatan performa klasifikasi melalui studi ablasi?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah ditetapkan, tujuan penelitian ini adalah sebagai berikut:

1. Mengimplementasikan dan mengevaluasi tiga skala arsitektur MedMamba (MedMamba-T, MedMamba-S, dan MedMamba-B) guna memetakan trade-off antara jumlah parameter, penggunaan VRAM, dan akurasi diagnostik.
2. Menerapkan dan menganalisis perbandingan paradigma pelatihan berbasis Supervised Learning dan Contrastive Learning untuk penanganan

ketidakseimbangan kelas medis.

3. Menguji kemampuan generalisasi model melalui pengujian lintas-dataset (cross-dataset) serta mengkuantifikasi dampak kebocoran data dengan membandingkan evaluasi pada DermaMNIST-origin, DermaMNIST-C, dan Fitzpatrick17k-C.
4. Melaksanakan studi ablasi terstruktur pada arsitektur MedMamba-S untuk mengisolasi efek dari skema loss function (Class-Weighted Loss), pre-training initialization, dan strategi augmentasi.

1.4 Batasan Masalah

Berikut adalah batasan yang diberlakukan dalam penelitian ini:

1. Arsitektur model yang dievaluasi berfokus pada keluarga MedMamba (MedMamba-T, MedMamba-S, dan MedMamba-B).
2. Dataset yang digunakan terbatas pada citra dermatologi publik: DermaMNIST-origin, DermaMNIST-C, dan Fitzpatrick17k-C.
3. Evaluasi kinerja mencakup metrik performa klinis (Balanced Accuracy, Macro-F1, MCC), reliabilitas prediksi (Expected Calibration Error / ECE), dan efisiensi fisik perangkat keras (jumlah parameter, GFLOPs, latensi inferensi, dan konsumsi VRAM).

1.5 Manfaat Penelitian

Manfaat yang diharapkan dari hasil penelitian ini meliputi:

1. **Manfaat Akademis dan Teoritis**: memberikan bukti empiris mengenai efisiensi linier arsitektur State Space Models (Mamba) pada citra medis dermatologi, serta menyajikan metodologi evaluasi lintas-dataset yang bersih dari kebocoran data (data leakage).
2. **Manfaat Praktis dan Klinis**: menyediakan rujukan arsitektur model diagnostik AI yang ringan, presisi, dan efisien sehingga siap diimplementasikan pada perangkat Edge AI di fasilitas kesehatan dengan

keterbatasan infrastruktur.

1.6 Sistematika Penulisan

Sistematika penulisan berisi pembahasan apa yang akan ditulis disetiap Bab. Sistematika pada umumnya berupa paragraf yang setiap paragraf mencerminkan bahasan setiap Bab.

Bab I

Bab ini berisikan penjelasan latar belakang dari topik penelitian yang berlangsung, rumusan masalah dari masalah yang dihadapi pada penjelasan di latar belakang, tujuan dari penelitian, batasan dari penelitian, manfaat dari hasil penelitian, dan sistematika penulisan tugas akhir.

Bab II

Bab ini membahas mengenai tinjauan pustaka dari penelitan terdahulu dan dasar teori yang berkaitan dengan penelitian ini.

Bab III

Bab ini berisikan penjelasan alur kerja sistem, alat dan data yang digunakan, metode yang digunakan, dan rancangan pengujian.

Bab IV

Bab ini membahas hasil implementasi dan pengujian dari penelitian yang dilakukan, serta analisis dan evaluasi yang dapat dipetik dari hasil.

Bab V

Bab ini membahas kesimpulan dari hasil penelitian dan juga saran untuk penelitian selanjutnya.

BAB II
TINJAUAN PUSTAKA

2.1 Tinjauan Pustaka

Pengembangan kecerdasan buatan di bidang klasifikasi citra medis dermatologi mengalami transformasi pesat dalam kurun waktu lima tahun terakhir (2021–2026). Penelitian terdahulu berfokus pada upaya mengatasi dua tantangan utama: ketidakseimbangan kelas (*imbalanced class*) yang ekstrem [19] dan efisiensi komputasi model saat disebarkan pada perangkat berdaya komputasi terbatas (*edge devices*). Penelitian ini diposisikan untuk menutupi celah penelitian (*research gap*) dengan mengevaluasi skalabilitas arsitektur *State Space Models* (MedMamba-T, S, dan B), membandingkan skenario pelatihan *Supervised* dan *Contrastive Learning*, serta menguji daya tahan generalisasi model secara lintas-dataset (*cross-dataset*) pada data medis terkoreksi yang bebas dari kebocoran data (*data leakage*).

Berikut adalah pembahasan sistematis mengenai penelitian-penelitian terdahulu yang menjadi pijakan utama penelitian ini:

1. Investigating the Quality of DermaMNIST and Fitzpatrick17k Dermatological Image Datasets. Penulis Tahun: Kumar Abhishek, Aditi Jain, dan Ghassan Hamarneh (2025). Penjelasan Isi: Penelitian ini mengevaluasi integritas dan kualitas dua dataset citra dermatologi terpopuler, yaitu DermaMNIST dan Fitzpatrick17k, yang banyak digunakan sebagai benchmark algoritma AI medis. Metode Penelitian: Menggunakan pustaka *fastdup*, analisis *embeddings* visual, serta verifikasi manual untuk mengidentifikasi duplikasi, kesalahan label (*mislabeling*), dan kebocoran data antar partisi. Hasil Penelitian Pengujian: Menemukan ditemukannya kebocoran data (*data leakage*) sebesar 13,47% (1.006 dari 7.470 lesi unik) pada DermaMNIST murni akibat pemisahan berbasis citra

(*image-level split*), bukan lesi/pasien (*patient-level split*). Penelitian ini menerbitkan versi perbaikan berupa *DermaMNIST-C* dan *Fitzpatrick17k-C*. Analisis Penulis: Penelitian ini memberikan kontribusi kritis terhadap validitas ilmiah AI medis. Keterbatasannya adalah belum mengevaluasi performa arsitektur modern ber-kompleksitas linear seperti Mamba pada dataset terkoreksi tersebut.

2. MedMamba: Vision Mamba for Medical Image Classification. Yubiao Yue dan Zhiming Li (2024). Mengembangkan arsitektur hibrida baru berbasis *State Space Models* (SSM) bernama MedMamba untuk menangani klasifikasi citra medis multidomain. Mengintegrasikan *Convolutional layers* untuk fitur lokal spasial dengan *Visual State Space Module* (VSSM) yang menggunakan mekanisme *selective scan* 4-arah (*Cross-Scan Module*) ber-kompleksitas linear $O(N)$. MedMamba mencapai akurasi dan *Macro-F1* yang lebih unggul dibandingkan CNN (ResNet) dan Vision Transformer (Swin-ViT) [20] pada dataset MedMNIST dengan konsumsi memori VRAM yang jauh lebih hemat. Menjadi keunggulan utama dalam efisiensi komputasi. Keterbatasannya, pengujian masih dilakukan pada dataset standar murni yang berpotensi mengandung kebocoran data serta belum menguji varian skalabilitas (T/S/B) secara lintas-dataset.
3. MedMambaLite: Hardware-aware Mamba for Medical Image Classification. Ruhollah Aalishah, Mahdi Navardi, dan Tinoosh Mohsenin (2025). Mengoptimalkan arsitektur Mamba agar dapat dieksekusi secara efisien pada akselerator perangkat keras *Edge AI* klinis. Menerapkan teknik *hardware-aware architectural search*, pemangkasan parameter (*pruning*), dan kuantisasi terarah. Berhasil memangkas konsumsi energi hingga 63% pada platform NVIDIA Jetson Orin dengan degradasi akurasi kurang dari 1%. Keunggulannya terbukti secara praktis untuk *deployment* medis. Keterbatasannya belum menguji ketahanan model saat dihadapkan

pada skenario *Contrastive Learning* dan *Cross-dataset generalization*.

4. Efficient Deep Learning for Medical Imaging: Bridging the Gap Between High-Performance AI and Clinical Deployment. Cuong Manh Nguyen dan Truong-Son Hy (2026). Membahas kesenjangan antara akurasi model AI di laboratorium dengan persyaratan efisiensi komputasi pada implementasi klinis nyata (*Deployment-First AI*). Studi komparatif literatur dan eksperimen *benchmark* terhadap berbagai arsitektur ringan (CNN, ViT, SSM) berdasarkan metrik akurasi, latensi inferensi, dan jejak memori. Mengidentifikasi model berkompleksitas linear sebagai salah satu kategori arsitektur efisien yang sedang berkembang untuk menyeimbangkan pemahaman konteks global dan efisiensi memori. Memberikan pijakan teoritis yang kuat, namun memerlukan pembuktian eksperimental secara spesifik pada kasus dermatologi yang sangat tidak seimbang.
5. Adaptive Distribution-aware Transformer for Multi-scale Visual Representation Learning on Imbalanced and Low-resolution Data. Sakib Ahammed, Xia Cui, Wenqi Lu, dan Moi Hoon Yap (2026). Menangani masalah ketidakseimbangan kelas ekstrem dan citra beresolusi rendah pada dataset dermatologi. Menggabungkan arsitektur *Adaptive Transformer* dengan fungsi kerugian *Distribution-aware Adaptive (DA) Loss*. Meningkatkan skor *Macro-F1* dan *Recall* secara signifikan pada kelas-kelas minoritas langka pada dataset ISIC dan HAM10000. Sangat efektif menangani *imbalanced data*, namun mekanisme atensi transformer masih memerlukan memori yang lebih besar dibandingkan Mamba.

Tabel 2.1 Literasi Penelitian Terdahulu

No.	Judul & Penulis	Masalah	Metode	Hasil
1.	Investigating the Quality of DermaMNIST and Fitzpatrick17k [14]	Adanya kebocoran data (*data leakage*) dan duplikasi pada dataset benchmark medis	Analisis *fastdup*, *embeddings*, dan pemisahan terisolasi pasien	Menemukan 13,47% kebocoran data DermaMNIST dan merilis *DermaMNIST-C* serta *Fitzpatrick17k-C*.
2.	MedMamba: Vision Mamba for Medical Image Classification [12]	Kompleksitas kuadratik $O(N^2)$ pada ViT membebani memori VRAM	Hibrida CNN + *Visual State Space Module* (VSSM) $O(N)$	Akurasi dan efisiensi memori melampaui ResNet dan Swin-ViT pada MedMNIST.
3.	MedMambaLite: Hardware-aware Mamba [13]	Tingginya konsumsi daya model AI pada perangkat *Edge AI* medis	*Hardware-aware pruning* dan kuantisasi Mamba	Menghemat energi hingga 63% pada platform NVIDIA Jetson Orin.

No.	Judul & Penulis	Masalah	Metode	Hasil
4.	Efficient Deep Learning for Medical Imaging [1]	Kesenjangan antara performa AI laboratorium dengan *clinical deployment*	Tinjauan komparatif arsitektur *lightweight* (CNN, ViT, SSM)	Model berkompleksitas linear diidentifikasi sebagai kategori efisien yang berkembang untuk paradigma *Deployment-First AI*.
5.	Adaptive Distribution-aware Transformer [21]	Ketidakseimbangan kelas ekstrem dan citra medis beresolusi rendah	*Adaptive Transformer* + *Distribution-aware Adaptive Loss*	Meningkatkan *Macro-F1* dan *Recall* kelas minoritas secara signifikan.

2.2 Dasar Teori

Sub-bab ini menguraikan landasan teori dan konsep ilmiah yang digunakan dalam pelaksanaan tugas akhir ini. Mengambil inspirasi dari struktur landasan teori pada penelitian terdahulu [7], sub-bab ini dikembangkan lebih lanjut dengan mengintegrasikan dua aspek pembeda utama, yaitu penggunaan dataset klinis *Fitzpatrick17k-C* di samping *DermaMNIST-C*, serta penerapan keluarga arsitektur *State Space Models* (*MedMamba-T*, *MedMamba-S*, dan *MedMamba-B*) sebagai pengganti arsitektur CNN konvensional.

2.2.1 DermaMNIST-C

DermaMNIST merupakan salah satu dataset publik terpopuler dalam konsorsium *MedMNIST v2* [15] yang diturunkan langsung dari dataset dermatoskopi *HAM10000* (*Human Against Machine with 10000 training images*) [22]. Dataset ini terdiri dari 10.015 citra lesi kulit berpigmen yang dikelompokkan ke dalam 7 kategori diagnosis medis [7]. Kumpulan penyakit ini merepresentasikan lebih dari 95% kasus klinis lesi kulit yang dijumpai dalam konsulitasi dermatologi harian [14].

Meskipun digunakan secara luas pada ratusan publikasi ilmiah, investigasi mutakhir oleh Abhishek et al. (2025) mengungkap bahwa DermaMNIST murni mengalami cacat integritas data berupa kebocoran data (*data leakage*) sebesar 13,47% (1.006 dari 7.470 lesi unik) [14]. Kebocoran ini terjadi akibat pemisahan folder *train*, *val*, dan *test* yang dilakukan di tingkat gambar (*image-level split*), sehingga gambar dari lesi pasien yang sama muncul simultan di folder pelatihan dan pengujian [14]. Selain itu, proses pembuatan citra beresolusi 224×224 piksel pada DermaMNIST asli dilakukan dengan menginterpolasi ulang citra 28×28 menggunakan *nearest neighbor*, yang menyebabkan pikselasi parah dan hilangnya detail struktur dermatoskopi [14].

Versi terkoreksi, **DermaMNIST-C**, menyelesaikan permasalahan tersebut dengan melakukan pemisahan terisolasi di tingkat lesi/pasien (*lesion-level*

disjoint split) serta melakukan pemotongan dan pencuplik-ulangan (*resizing*) secara langsung dari resolusi asli 600×450 piksel menggunakan interpolasi *bicubic* [14]. Rincian dari ketujuh kategori lesi kulit pada DermaMNIST-C diuraikan sebagai berikut:

2.2.1.1 Actinic Keratoses and Intraepidhelial Carcinoma (`akiec`)

Actinic Keratoses (AK) merupakan lesi pra-kanker pada sel epidermal kulit yang dipicu oleh paparan radiasi sinar ultraviolet (UV) secara kronis [7]. Secara biologis, AK dianggap sebagai bentuk karsinoma in-situ awal dari *Squamous Cell Carcinoma* (SCC). Ketika sel-sel neoplastik atypik tersebut menembus membran basalis epidermis dan menyerang lapisan dermis di bawahnya, lesi ini berkembang menjadi *Intraepidhelial Carcinoma*. Pada dataset DermaMNIST-C, kelas `akiec` tergolong sebagai kelas minoritas dengan proporsi sebesar 3,27% (327 sampel) [14].

2.2.1.2 Basal Cell Carcinoma (`bcc`)

Basal Cell Carcinoma (BCC) merupakan jenis kanker kulit non-melanoma paling umum yang timbul dari sel-sel basal pada lapisan terdalam epidermis [7]. Kanker ini memiliki laju pertumbuhan yang relatif lambat dengan angka metastasis yang rendah, namun dapat menyebabkan kerusakan jaringan lokal yang destruktif jika tidak diintervensi. BCC paling sering muncul pada area tubuh yang terpapar sinar matahari secara konstan, seperti wajah dan leher. Kategori `bcc` mencakup 5,13% (514 sampel) dari total populasi dataset [14].

2.2.1.3 Benign Keratosis-Like Lesions (`bkl`)

Benign Keratosis-Like Lesions (BKL) merupakan kategori komposit yang menggabungkan tiga varian lesi kulit jinak (*benign*), yaitu *seborrheic keratoses*, *solar lentigo*, dan *lichen planus-like keratoses* [7], [22]. Penggabungan ketiga varian klinis ini dilakukan karena ketiganya memiliki gambaran struktural biologis serta morfologi dermatoskopik yang saling beririsan. Pola visual BKL

yang sangat bervariasi menjadi tantangan tersendiri bagi ekstraksi fitur model *deep learning*. Kategori ini mencakup 10,97% (1.099 sampel) dari dataset [14].

2.2.1.4 Dermatofibroma (`df`)

Dermatofibroma (DF) adalah nodul kulit jinak pada lapisan dermal yang terbentuk sebagai reaksi proliferasi fibrosit sekunder akibat trauma fisik ringan, seperti gigitan serangga atau luka gores [7]. Ciri dermatoskopik khas dari *dermatofibroma* adalah ditemukannya struktur jaring retikular pigmen di area perifer yang mengelilingi daerah pusat berwarna putih (*central white patch*). Kategori `df` merupakan **kelas paling minoritas** pada DermaMNIST-C dengan proporsi hanya sebesar 1,15% (115 sampel) [14].

2.2.1.5 Melanoma (`mel`)

Melanoma merupakan neoplasma ganas paling agresif dan mematikan yang berasal dari transformasi maligna sel-sel melanosit [7]. Melanoma memiliki potensi metastasis yang sangat tinggi ke organ-organ vital melalui invasi sistem limfatik dan pembuluh darah. Secara dermatoskopik, melanoma ditandai dengan ketidaksimetrisan bentuk (asimetri), batas lesi yang tidak teratur, variasi warna yang heterogen (hitam, cokelat, biru, merah), serta ditemukannya globula dan jaringan pigmen atypik. Kategori `mel` mencakup 11,11% (1.113 sampel) dari total data [14].

2.2.1.6 Melanocytic Nevi (`nv`)

Melanocytic Nevi (tahi lalat) merupakan proliferasi jinak dari sel-sel melanosit [7]. Lesi ini bersifat non-maligna dan memiliki risiko transformasi ganas yang sangat minimal. Karakteristik visual *nevi* bervariasi mulai dari makula datar berpigmen hingga papula yang menonjol. Pada dataset DermaMNIST-C, kelas `nv` merupakan **kelas mayoritas yang sangat dominan**, mencakup hingga **66,95% (6.705 sampel)** dari keseluruhan dataset [14]. Dominasi ekstrem ini menjadi pemicu utama timbulnya bias prediksi pada

fungsi kerugian konvensional [7].

2.2.1.7 Vascular Lesions (`vasc`)

Vascular Lesions mencakup kelompok kelainan pembuluh darah kulit yang bersifat jinak, seperti *cherry angioma*, *angiokeratoma*, *pyogenic granuloma*, dan lesi perdarahan (*intralesional hemorrhage*) [7]. Ciri visual dermatoskopi utama dari kelas ini adalah ditemukannya gambaran gumpalan merah (*red clods*) atau rongga pembuluh darah (*lacunes*) berwarna ungu hingga biru-kehitaman. Kelas `vasc` tergolong sebagai kelas minoritas dengan proporsi 1,42% (142 sampel) [14].

2.2.2 Fitzpatrick17k-C

Untuk menguji keandalan generalisasi model secara lintas-dataset (*cross-dataset generalization*), penelitian ini mengikutsertakan dataset **Fitzpatrick17k-C** [14], [16]. Fitzpatrick17k murni yang dirilis oleh Groh et al. (2021) merupakan salah satu dataset citra medis klinis (*in-the-wild*) terbesar yang terdiri dari 16.577 citra yang mencakup 114 kategori penyakit kulit dan dilengkapi dengan anotasi skala tipe warna kulit *Fitzpatrick Skin Tone* (FST I–VI) [16].

Namun demikian, investigasi oleh Abhishek et al. (2025) menemukan bahwa Fitzpatrick17k murni memiliki berbagai keterbatasan kualitas, meliputi ditemukannya duplikasi citra masif, ketidaksesuaian label diagnosis (*mislabeled images*), serta ketiadaan partisi pengujian baku (*held-out test set*) yang memicu variabilitas tinggi antar eksperimen [14].

Versi perbaikan Fitzpatrick17k-C mengatasi masalah ini dengan membuang citra duplikat dan citra berlabel salah, sehingga menghasilkan dataset bersih sebanyak 11.394 citra klinis [14]. Selain itu, Fitzpatrick17k-C menyediakan pembagian partisi baku *train-validation-test* berasio 70:10:20 yang terstratifikasi berdasarkan label diagnosis [14]. Evaluasi pada Fitzpatrick17k-C sangat krusial untuk menguji sejauh mana arsitektur linear

MedMamba (T/S/B) [12], [13] mampu menggeneralisasi fitur medis pada citra klinis dengan variasi pencahayaan dan keberagaman warna kulit pasien [1].

2.2.3 *Imbalanced Data*

Masalah ketidakseimbangan data (*imbalanced data*) terjadi ketika distribusi sampel antarkelas sangat tidak merata [19]. Pada DermaMNIST-C, kelas mayoritas *Melanocytic Nevi* (`nv`) mendominasi hingga ~67% data latih, sedangkan kelas minoritas seperti *Dermatofibroma* (`df`) dan *Vascular Lesions* (`vasc`) masing-masing hanya mencakup ~1,14% dan ~1,41% data.

Kondisi ini menyebabkan fungsi kerugian *Cross-Entropy* standar terbias ke arah kelas mayoritas, sehingga menghasilkan akurasi keseluruhan yang tinggi secara semu tetapi memiliki sensitivitas (*recall*) yang sangat rendah pada penyakit langka [7]. Untuk mengatasinya, penelitian ini menerapkan *Class-Weighted Cross-Entropy Loss* ($\mathcal{L}_{CWCE}$) [23]:

$$\mathcal{L}_{CWCE} = -\sum_{c=1}^{C} w_c \cdot y_c \log(\hat{y}_c) \qquad \text{(Rumus 2.1)}$$

di mana bobot penalti kelas w_c dihitung berdasarkan frekuensi terbalik sampel:

$$w_c = \frac{N_{total}}{C \cdot N_c} \qquad \text{(Rumus 2.2)}$$

dengan N_{total} adalah total sampel, C adalah jumlah kelas, dan N_c adalah jumlah sampel pada kelas c.

2.2.4 Arsitektur Model: Dari CNN/ViT ke State Space Models (MedMamba)

Berbeda dari penelitian [7] yang berfokus pada arsitektur CNN konvensional (*ResNet-18* dan *ResNet-50*), penelitian ini mengeksplorasi arsitektur mutakhir berbasis *State Space Models* (SSM) yaitu **MedMamba** [12].

2.2.4.1 Prinsip Dasar State Space Models (SSM) dan Mamba

State Space Models memodelkan sistem sekuensial kontinu yang memetakan masukan $x(t) \in \mathbb{R}$ ke keluaran $y(t) \in \mathbb{R}$ melalui variabel keadaan tersembunyi $h(t) \in \mathbb{R}^N$:

$$h'(t) = \mathbf{A}h(t) + \mathbf{B}x(t) \tag{Rumus 2.3}$$

$$y(t) = \mathbf{C}h(t) \tag{Rumus 2.4}$$

Untuk diimplementasikan pada data diskrit, persamaan di atas didiskretisasi menggunakan aturan *Zero-Order Hold* (ZOH) dengan parameter langkah $\mathbf{\Delta}$:

$$\bar{\mathbf{A}} = \exp(\mathbf{\Delta A}), \quad \bar{\mathbf{B}} = (\mathbf{\Delta A})^{-1}(\bar{\mathbf{A}} - \mathbf{I}) \cdot \mathbf{\Delta B} \tag{Rumus 2.5}$$

$$h_t = \bar{\mathbf{A}}h_{t-1} + \bar{\mathbf{B}}x_t, \quad y_t = \mathbf{C}h_t \tag{Rumus 2.6}$$

Arsitektur Mamba menggabungkan pemrosesan selektif terbobot data (*Selective Scan Mechanism*) dengan kompleksitas komputasi linear $O(N)$ [11], menggantikan kompleksitas kuadratik $O(N^2)$ pada *Vision Transformer* (ViT) dan variannya [2], [12], [20].

2.2.4.2 Modul Visual State Space Module (VSSM) dan Skalabilitas MedMamba

MedMamba mengintegrasikan *Convolutional layers* untuk fitur lokal dengan modul *Visual State Space* (VSSM) yang menggunakan *Cross-Scan Module* (CSM) untuk memindai citra 2D ke 4 arah spasial [12], [24].

Penelitian ini menguji tiga varian skala MedMamba untuk memetakan *trade-off* antara kapasitas parameter dan efisiensi komputasi:

- **MedMamba-T (*Tiny*):** Dikonfigurasi dengan kedalaman `depths = [1, 2]` dan dimensi `dims = [3, 4]` (~14,5M parameter).
- **MedMamba-S (*Small*):** Dikonfigurasi dengan kedalaman `depths = [1, 5]` dan dimensi `dims = [3, 4]` (~22,8M parameter) — sebagai

fokus utama studi.

- **MedMamba-B (*Base*):** Dikonfigurasi dengan kedalaman `depths = [1, 6]` dan dimensi `dims = [7]` (~47,1M parameter) — sebagai **baseline *upper-bound***.

2.2.5 Paradigma Pelatihan: Supervised vs. Contrastive Learning

Selain pengujian *Supervised Learning* terawasi, penelitian ini mengimplementasikan paradigma *Supervised Contrastive Learning* (SupCon) [18]. SupCon melatih *backbone* MedMamba untuk memetakan proyeksi fitur z_i ke dalam ruang laten tempat pasangan sampel dari kelas diagnosis yang sama didekatkan, sementara sampel dari kelas berbeda dipisahkan:

$$\mathcal{L}_{SupCon} = \sum_{i \in I} \frac{-1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(z_i \cdot z_p / \tau)}{\sum_{a \in A(i)} \exp(z_i \cdot z_a / \tau)} \qquad \text{(Rumus 2.7)}$$

di mana $P(i)$ adalah himpunan indeks sampel yang memiliki label kelas sama dengan i, dan $\tau > 0$ adalah parameter temperatur.

2.2.6 Metrik Evaluasi, Kalibrasi, dan Efisiensi Perangkat Keras

Mengembangkan metrik pada [7], [25], evaluasi kinerja model dikelompokkan ke dalam tiga kategori utama:

2.2.6.1 Metrik Kinerja Klasifikasi Multikelas

Berdasarkan *Confusion Matrix* multikelas (TP_c, FP_c, TN_c, FN_c), dihitung metrik berikut [7]:

$$\text{Accuracy} = \frac{\sum_{c=1}^{C} TP_c}{N_{total}} \quad \text{(Rumus 2.8)}$$

$$\text{Macro Precision} = \frac{1}{C}\sum_{c=1}^{C}\frac{TP_c}{TP_c + FP_c} \quad \text{(Rumus 2.9)}$$

$$\text{Macro Recall} = \frac{1}{C}\sum_{c=1}^{C}\frac{TP_c}{TP_c + FN_c} \quad \text{(Rumus 2.10)}$$

$$\text{Macro F1-Score} = \frac{1}{C}\sum_{c=1}^{C} 2 \cdot \frac{\text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \quad \text{(Rumus 2.11)}$$

$$\text{MCC} = \frac{c \cdot s - \sum_k^C p_k t_k}{\sqrt{\left(s^2 - \sum_k^C p_k^2\right)\left(s^2 - \sum_k^C t_k^2\right)}} \quad \text{(Rumus 2.12)}$$

di mana *Matthews Correlation Coefficient* (MCC) memberikan pengujian yang adil pada kondisi *imbalanced class* [26].

2.2.6.2 Metrik Reliabilitas Kalibrasi Prediksi

Untuk menjamin keamanan klinis agar tingkat kepercayaan model (*confidence score*) selaras dengan akurasi aktualnya, diukur metrik *Expected Calibration Error* (ECE) [27]:

$$\text{ECE} = \sum_{m=1}^{M}\frac{|B_m|}{N}\left|\text{acc}(B_m) - \text{conf}(B_m)\right| \quad \text{(Rumus 2.13)}$$

di mana sampel dikelompokkan ke dalam M bin interval kepercayaan B_m.

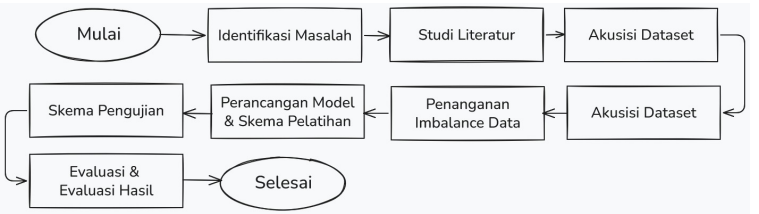
2.2.7 Metrik Efisiensi Komputasi Hardware

Efisiensi komputasi fisik diukur secara langsung pada GPU laptop NVIDIA RTX 2050 (4 GB VRAM) mencakup: konsumsi VRAM puncak (MB/GB), *throughput* (citra/detik), latensi inferensi per sampel (ms), jumlah parameter terparameterisasi, serta GFLOPs.

BAB III
METODE PENELITIAN

3.1 Alur Penelitian

Penelitian ini berfokus pada evaluasi skalabilitas, generalisasi lintas-dataset, dan efisiensi komputasi dari keluarga arsitektur MedMamba (MedMamba-T, MedMamba-S, dan MedMamba-B) pada klasifikasi citra penyakit kulit yang tidak seimbang. Alur pelaksanaan penelitian secara terstruktur ditunjukkan pada diagram berikut (*flowchart*) seperti yang terlihat pada Gambar 3.1.



Gambar 3.1 Alur Penelitian

3.2 Penjabaran Langkah Penelitian

Penjelasan dari setiap langkah pada alur penelitian akan dijelaskan secara merinci untuk memberikan detail yang jelas terhadap metode yang digunakan. Berikut penjelasan dari setiap langkah penelitian tersebut.

3.2.1 Identifikasi Masalah

Tahap awal yang dilakukan sebelum memulai penelitian adalah identifikasi masalah. Identifikasi dilakukan dengan cara menelaah secara mendalam karakteristik dataset dermatologi medis serta keterbatasan arsitektur model klasifikasi yang ada saat ini. Pada klasifikasi penyakit kulit menggunakan dataset DermaMNIST, ditemukan adanya ketidakseimbangan kelas yang sangat ekstrem di mana kelas mayoritas *Melanocytic Nevi* (nv) mendominasi hingga ~67% dari

keseluruhan sampel, sedangkan kelas minoritas seperti *Dermatofibroma* (`df`) dan *Vascular Lesions* (`vasc`) masing-masing hanya mencakup ∼1,14% dan ∼1,41% data. Kondisi ketimpangan ini memicu bias prediksi pada fungsi kerugian konvensional dan menurunkan sensitivitas model terhadap penyakit langka [7]. Selain itu, investigasi kualitas data mengungkapkan ditemukannya kebocoran data (*data leakage*) sebesar 13,47% pada DermaMNIST murni akibat pemisahan berbasis gambar (*image-level split*), yang mengakibatkan inflasi performa secara semu [14]. Di sisi lain, penggunaan arsitektur *Vision Transformer* (ViT) memicu masalah baru berupa kompleksitas komputasi kuadratik $O(N^2)$ yang sangat membebani memori VRAM [8]. Berdasarkan permasalahan tersebut, penelitian ini mengevaluasi arsitektur *State Space Models* (MedMamba) ber-kompleksitas linear $O(N)$ pada dataset terkoreksi (*DermaMNIST-C* dan *Fitzpatrick17k-C*) untuk mengatasi masalah ketidakseimbangan data, kebocoran data, dan keterbatasan efisiensi komputasi pada perangkat *Edge AI*.

3.2.2 Studi Literatur

Tahap studi literatur dilakukan dengan mengumpulkan, mempelajari, dan mengkaji berbagai sumber akademis terpercaya yang diterbitkan dalam kurun waktu lima tahun terakhir (2021–2026). Referensi yang dikumpulkan berfokus pada lima pilar utama, yaitu: konsep dasar pemrosesan sekuensial linear berbasis *State Space Models* (SSM) dan modul *Visual State Space* (VSSM) pada arsitektur Mamba [11], [12], temuan investigasi integritas dataset medis terkait *data leakage* dan duplikasi [14], paradigma *Supervised Contrastive Learning* (SupCon) untuk ekstraksi representasi fitur yang robust [18], teknik penanganan *imbalanced data* melalui *Class-Weighted Loss* dan augmentasi hibrida [19], [28], serta metrik evaluasi keandalan klinis seperti *Expected Calibration Error* (ECE) [27] dan metrik efisiensi *hardware* [3]. Tahap studi literatur ini bertujuan untuk membangun landasan teoritis yang kokoh serta memberikan kerangka acuan yang valid dalam menyusun skenario eksperimen dan menganalisis hasil

pengujian.

3.2.3 Akuisisi Dataset

Proses pengumpulan data dalam penelitian ini dilakukan dengan mengunduh dataset publik dari repositori resmi Zenodo dan MedMNIST [15]. Tiga himpunan data utama yang diakuisisi meliputi *DermaMNIST-C*, *Fitzpatrick17k-C*, dan *DermaMNIST-origin*. Dataset *DermaMNIST-C* terdiri dari 10.015 citra dermatoskopi yang telah dibersihkan dari kebocoran data menggunakan pemisahan terisolasi di tingkat pasien/lesi (*lesion-level disjoint split*) [14]. Dataset *Fitzpatrick17k-C* berisi 11.394 citra medis klinis (*in-the-wild*) yang telah dibersihkan dari duplikasi dan kesalahan label, serta dilengkapi dengan anotasi skala warna kulit *Fitzpatrick Skin Tone* (FST I–VI) dan partisi baku *train-validation-test* (70:10:20) [14], [16]. Sementara itu, dataset *DermaMNIST-origin* diikutsertakan secara khusus sebagai pembanding untuk mengkuantifikasi secara eksperimental seberapa besar dampak kebocoran data terhadap inflasi skor akurasi model.

3.2.4 Preprocessing Data

Tahap *preprocessing data* dilakukan untuk menyiapkan citra medis agar berada dalam format baku yang optimal sebelum dimasukkan ke dalam proses pelatihan model. Langkah pertama adalah penyesuaian resolusi citra (*resizing*) secara langsung dari citra resolusi tinggi/asli menjadi dimensi 224×224 piksel menggunakan interpolasi *bicubic*. Metode ini dipilih untuk menghindari efek pikselasi buruk dan hilangnya detail morfologi halus pada struktur lesi yang biasa terjadi pada metode *upscaling nearest neighbor* [14]. Langkah selanjutnya adalah normalisasi nilai intensitas piksel, di mana rentang nilai piksel $[0, 255]$ dikonversi menjadi tensor berformat *floating-point* (*float*) pada rentang $[0.0, 1.0]$, kemudian distandarisasi menggunakan nilai rata-rata (*mean*) dan deviasi standar (*standard deviation*) terhitung dari populasi dataset.

3.2.5 Penanganan Imbalanced Data dan Augmentasi

Guna mengatasi ketimpangan distribusi kelas pada dataset *DermaMNIST-C*, diterapkan kombinasi strategi di tingkat fungsi kerugian dan manipulasi data latih. Pada tingkat algoritma, diterapkan *Class-Weighted Cross-Entropy Loss* ($\mathcal{L}_{CWCE}$) yang secara otomatis menghitung bobot penalti terbalik berdasarkan frekuensi kemunculan sampel pada tiap kelas, sehingga memaksa gradien model untuk memberikan perhatian lebih pada kelas-kelas minoritas [19]. Pada tingkat data, diterapkan teknik *Hybrid Data Augmentation* secara khusus pada porsi data latih kelas minoritas (seperti `df`, `vasc`, dan `akiec`). Teknik augmentasi hibrida ini menggabungkan transformasi geometris mencakup pencerminan acak (*Random Horizontal/Vertical Flip*) dan rotasi acak hingga 20 derajat, dengan transformasi fotometrik berupa manipulasi warna (*Color Jitter*) serta penghapusan daerah piksel acak (*Random Erasing*). Penerapan teknik ini bertujuan untuk memperkaya variasi visual sampel minoritas tanpa mengubah label biologisnya [28].

3.2.6 Perancangan Model dan Skenario Pelatihan

Tahap perancangan model diawali dengan mengonfigurasi tiga skala arsitektur *Visual State Space Model* (MedMamba) [12], yaitu *MedMamba-T* (~14,5M parameter) sebagai pembanding *lightweight*, *MedMamba-S* (~22,8M parameter) sebagai fokus utama penelitian, dan *MedMamba-B* (~47,1M parameter) sebagai *baseline upper-bound*. Pelatihan dilakukan dalam dua paradigma terpisah: *Supervised Learning* terawasi langsung dan *Supervised Contrastive Learning* (SupCon). Pada paradigma SupCon, *backbone* MedMamba dilatih terlebih dahulu pada tahap *pre-training* untuk memetakan proyeksi fitur ke dalam ruang laten menggunakan *contrastive loss*, sebelum dilanjutkan dengan *fine-tuning* pada lapisan klasifikasi linier. Proses pelatihan dieksekusi menggunakan *AdamW optimizer*, *Cosine Annealing Learning Rate Scheduler*, dan optimasi *Automatic Mixed Precision* (AMP) FP16 untuk

menghemat memori. Untuk menjamin reproduksibilitas dan kestabilan hasil statistik, penguncian benih acak (*multi-seed*) diterapkan, serta pengujian berbasis *5-Fold Cross Validation* dijalankan pada dataset yang tidak memiliki pemisahan baku.

3.2.7 Evaluasi Model

Tahap evaluasi dilakukan untuk mengukur dan menganalisis kinerja model yang telah dilatih berdasarkan tiga dimensi utama [25]. Dimensi pertama adalah performa diagnostik klinis multikelas yang diukur menggunakan metrik *Balanced Accuracy*, *Macro Precision*, *Macro Recall*, *Macro F1-Score*, serta *Matthews Correlation Coefficient* (MCC) untuk menjamin penilaian yang adil pada kondisi *imbalanced class*. Dimensi kedua adalah reliabilitas kalibrasi prediksi yang diukur melalui *Expected Calibration Error* (ECE) guna menilai sejauh mana tingkat kepercayaan prediksi (*confidence score*) model selaras dengan akurasi aktualnya. Dimensi ketiga adalah efisiensi komputasi fisik yang diukur secara langsung pada GPU laptop NVIDIA RTX 2050 (4 GB VRAM), meliputi konsumsi VRAM puncak (*peak VRAM*), latensi inferensi per sampel (ms), *throughput* (citra/detik), serta jumlah parameter terparameterisasi dan GFLOPs.

3.3 Alat dan Bahan Tugas Akhir

Berisi alat-alat dan bahan-bahan yang digunakan dalam penelitian.

3.3.1 Alat

Berikut merupakan alat-alat yang digunakan dalam pelaksanaan penelitian:

1. *Laptop* yang dilengkapi dengan unit pemroses grafis NVIDIA GeForce RTX 2050 Laptop GPU berkapasitas memori 4 GB GDDR6 VRAM berbasis arsitektur Ampere dengan *Compute Capability* 8.6. Perangkat keras pendukung mencakup pemroses utama *multi-core* dan memori sistem sebesar 16 GB RAM DDR4.

2. Arch Linux
3. Github
4. Python 3.10
5. CUDA Toolkit 12.1
6. Code editor Microsoft Visual Studio Code, Google Colab, dan Kaggle Notebook
7. Library Python: PyTorch, numpy, pandas, scikit-learn, matplotlib, seaborn.

3.3.2 Bahan Penelitian

Bahan utama yang digunakan dalam penelitian ini terdiri dari tiga himpunan data citra medis publik serta satu bobot *pretrained*. Bahan pertama adalah dataset *DermaMNIST-C* yang berisi 10.015 citra dermatoskopi terkoreksi dan bebas dari kebocoran data melalui pemisahan terisolasi di tingkat pasien/lesi (*lesion-level disjoint split*) [14]. Bahan kedua adalah dataset *Fitzpatrick17k-C* yang mencakup 11.394 citra medis klinis (*in-the-wild*) terkoreksi, bebas dari duplikasi dan kesalahan label, serta dilengkapi dengan anotasi warna kulit *Fitzpatrick Skin Tone* (FST I–VI) [16]. Bahan ketiga adalah dataset *DermaMNIST-origin* yang diikutsertakan secara khusus untuk menguji dampak langsung kebocoran data. Bahan terakhir adalah bobot *pretrained* `Medmamba.pth` [12] yang diuji pemuatannya secara parsial (*partial initialization*) untuk dibandingkan efektivitasnya terhadap pelatihan dari awal (*random initialization*).

3.4 Metode Pengembangan

Metode pengembangan sistem berfokus pada perancangan arsitektur model *State Space Models*, penerapan paradigma pelatihan terawasi dan kontrastif, serta strategi mitigasi ketidakseimbangan data medis.

3.4.1 Arsitektur Model MedMamba

Arsitektur MedMamba menggabungkan lapisan konvolusi untuk ekstraksi fitur lokal spasial dengan modul *Visual State Space* (VSSM). Modul VSSM mengintegrasikan *Cross-Scan Module* (CSM) [24] yang memindai citra 2D secara linier $O(N)$ ke empat arah spasial mendatar dan tegak guna memodelkan konteks global tanpa beban memori kuadratik $O(N^2)$ seperti pada *Vision Transformer* (ViT). Penelitian ini menguji tiga varian skala MedMamba untuk memetakan *trade-off* antara kapasitas parameter dan efisiensi komputasi, meliputi *MedMamba-T* (*Tiny*) dengan kedalaman `depths =` dan dimensi `dims =` (∼14,5M parameter) sebagai pembanding *lightweight*, *MedMamba-S* (*Small*) dengan kedalaman `depths =` dan dimensi `dims =` (∼22,8M parameter) sebagai fokus utama penelitian, serta *MedMamba-B* (*Base*) dengan kedalaman `depths =` dan dimensi `dims =` (∼47,1M parameter) sebagai *baseline upper-bound*.

3.4.2 Supervised vs. Contrastive Learning

Pelatihan model dikembangkan melalui dua paradigma utama. Paradigma pertama adalah *Supervised Learning* langsung yang melatih model secara *end-to-end* menggunakan *Class-Weighted Cross-Entropy Loss* ($\mathcal{L}_{CWCE}$) dengan pengoptimasi *AdamW*, penjadwal *Cosine Annealing Learning Rate* dengan T_{max} terikat durasi epoch, serta optimasi *Automatic Mixed Precision* (AMP) FP16 untuk menjamin efisiensi alokasi memori VRAM. Paradigma kedua adalah *Supervised Contrastive Learning* (SupCon) [18] yang dibagi ke dalam dua tahap. Pada tahap pertama, *backbone* MedMamba dilatih menggunakan *SupCon Loss* dengan parameter temperatur $\tau = 0,07$ untuk mendekatkan vektor representasi fitur dari kelas yang sama dan memisahkan kelas yang berbeda di ruang laten. Pada tahap kedua, lapisan klasifikasi linier dipasang di atas *backbone* terfasilitasi tersebut untuk mengeksekusi prediksi label target secara langsung.

3.4.3 Strategi Mitigasi Data Tak Seimbang

Strategi penanganan data tak seimbang dikembangkan pada dua tingkatan terpisah. Pada tingkat algoritma, bobot penalti fungsi kerugian dihitung secara otomatis berdasarkan frekuensi terbalik populasi kelas untuk memberikan penalti gradien yang lebih besar pada kesalahan prediksi kelas langka [23]. Pada tingkat manipulasi data, diterapkan teknik *Hybrid Data Augmentation* secara khusus pada porsi data latih kelas minoritas seperti `df`, `vasc`, dan `akiec`. Augmentasi hibrida menggabungkan pembalikan acak (*Random Horizontal/Vertical Flip*) dan rotasi acak hingga 20 derajat untuk variasi geometris, serta manipulasi warna (*Color Jitter*) dan penghapusan daerah piksel acak (*Random Erasing*) untuk meningkatkan variasi fotometrik tanpa merusak informasi morfologi lesi [29].

3.5 Rancangan Pengujian dan Skema Eksperimen

Rancangan pengujian disusun ke dalam lima skenario eksperimen utama untuk menjawab seluruh hipotesis penelitian secara komprehensif. Skenario pertama adalah *In-Dataset Benchmark* yang mengevaluasi performa dasar ketiga varian MedMamba pada data bersih menggunakan pengujian *5-Fold Cross Validation* pada *DermaMNIST-C* dan pembagian partisi baku 70:10:20 pada *Fitzpatrick17k-C*. Skenario kedua adalah *Leakage Impact Test* yang melatih model pada *DermaMNIST-origin* kemudian mengujinya pada *DermaMNIST-C* dan *Fitzpatrick17k-C* guna mengkuantifikasi secara mendalam seberapa besar persentase akurasi yang terinflasi akibat kebocoran data.

Skenario ketiga adalah *Cross-Dataset Generalization* yang menguji daya tahan transferabilitas fitur antar-domain medis secara *zero-shot*, di mana model yang dilatih pada *DermaMNIST-C* diuji secara langsung pada *Fitzpatrick17k-C* (Arah A), dan sebaliknya model yang dilatih pada *Fitzpatrick17k-C* diuji pada *DermaMNIST-C* (Arah B). Skenario keempat adalah *Joint-Dataset Training* yang menggabungkan populasi data latih *DermaMNIST-C* dan *Fitzpatrick17k-C*

menjadi satu himpunan heterogen, lalu menguji performanya pada gabungan himpunan uji. Skenario kelima adalah *Studi Ablasi MedMamba-S* yang dieksekusi secara terisolasi pada *DermaMNIST-C* untuk membedah kontribusi spesifik dari penggunaan *Class-Weighted Loss*, inisialisasi bobot (*Random* vs *Partial Pretrained*), serta variasi penjadwalan *learning rate*.

3.6 Metrik Evaluasi

Kinerja dari setiap model yang dievaluasi diukur dan dianalisis secara kualitatif dan kuantitatif berdasarkan tiga dimensi utama.

3.6.1 Metrik Performa Klasifikasi Multikelas

Berdasarkan nilai *Confusion Matrix* multikelas (TP_c, FP_c, TN_c, FN_c), dihitung metrik *Balanced Accuracy* (Macro Recall) untuk mengukur rata-rata sensitivitas seluruh kelas tanpa terdistorsi oleh populasi mayoritas:

$$\text{Balanced Accuracy} = \frac{1}{C}\sum_{c=1}^{C}\frac{TP_c}{TP_c + FN_c} \qquad \text{(Rumus 3.1)}$$

Selain itu, dihitung pula metrik *Macro F1-Score* untuk mengukur keseimbangan antara *Precision* dan *Recall* secara rata-rata tidak terbobot:

$$\text{Macro F1-Score} = \frac{1}{C}\sum_{c=1}^{C}\frac{2 \cdot \text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \qquad \text{(Rumus 3.2)}$$

Untuk mengevaluasi keandalan klasifikasi multikelas pada kondisi ketimpangan kelas yang ekstrem secara lebih adil, dihitung metrik *Matthews Correlation Coefficient* (MCC) [26]:

$$\text{MCC} = \frac{c \cdot s - \sum_k^C p_k t_k}{\sqrt{\left(s^2 - \sum_k^C p_k^2\right)\left(s^2 - \sum_k^C t_k^2\right)}} \qquad \text{(Rumus 3.3)}$$

di mana c adalah total sampel yang terklasifikasi benar, s adalah total sampel, p_k adalah jumlah kali kelas k diprediksi, dan t_k adalah jumlah kali kelas k benar-benar muncul.

3.6.2 Metrik Reliabilitas Kalibrasi Prediksi

Guna menjamin keamanan klinis agar skor kepercayaan prediksi (*confidence score*) selaras dengan akurasi aktualnya, diukur metrik *Expected Calibration Error* (ECE) [27]. Pengukuran dilakukan dengan mengelompokkan N sampel ke dalam M bin interval kepercayaan B_m yang berjarak sama (misalnya $M = 10$):

$$\mathrm{ECE} = \sum_{m=1}^{M} \frac{|B_m|}{N} \left|\mathrm{acc}(B_m) - \mathrm{conf}(B_m)\right| \qquad \text{(Rumus 3.4)}$$

di mana $\mathrm{acc}(B_m)$ menyatakan akurasi aktual dalam bin B_m dan $\mathrm{conf}(B_m)$ menyatakan rata-rata nilai kepercayaan prediksi pada bin tersebut. Sebagai metrik pendukung, dihitung pula nilai *Brier Loss* untuk menilai kesalahan kuadrat rata-rata antara probabilitas prediksi dengan vektor *one-hot* label sebenarnya.

3.6.3 Metrik Efisiensi Komputasi Hardware

Efisiensi komputasi fisik diukur secara langsung pada GPU laptop NVIDIA RTX 2050 (4 GB VRAM) mencakup empat indikator utama [13]. Indikator pertama adalah konsumsi VRAM puncak (*Peak VRAM Allocated*) yang dihitung dalam satuan megabyte/gigabyte menggunakan fungsi pemantauan memori internal PyTorch. Indikator kedua adalah latensi inferensi per sampel (*Inference Latency*) yang diukur dalam milidetik (ms) pada ukuran *batch* sama dengan satu. Indikator ketiga adalah *Throughput* yang mengukur jumlah citra yang berhasil diproses per detik (*images per second*). Indikator keempat adalah jejak fisik model yang dihitung melalui jumlah parameter terparameterisasi (dalam jutaan/M) serta total operasi titik kambang (*Giga Floating Point Operations* / GFLOPs).

DAFTAR PUSTAKA

[1] Cuong Manh Nguyen and Truong-Son Hy. **?**Efficient Deep Learning for Medical Imaging: Bridging the Gap Between High-Performance AI and Clinical Deployment**?** *arXiv preprint arXiv:2602.00910* (2026). arXiv: 2602.00910 [cs.CV].

[2] Sachin Mehta and Mohammad Rastegari. **?**MobileViT: Light-weight, General-Purpose, and Mobile-Friendly Vision Transformer**?** *arXiv preprint arXiv:2110.02178* (2022). arXiv: 2110.02178 [cs.CV].

[3] Mahsa Lavaei et al. **?**Resource-efficient medical image classification for edge devices**?** *arXiv preprint arXiv:2512.17515* (2025). arXiv: 2512.17515 [cs.CV].

[4] Andre Esteva et al. **?**Dermatologist-level classification of skin cancer with deep neural networks**?** *Nature* 542.7639 (2017), pp. 115–118.

[5] Geert Litjens et al. **?**A survey on deep learning in medical image analysis**?** *Medical Image Analysis* 42 (2017), pp. 60–88.

[6] Kaiming He et al. **?**Deep residual learning for image recognition**?** *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, pp. 770–778.

[7] Arkan Hariz. **?**Analisis Performa Arsitektur ResNet-18 dan ResNet-50 dengan Penerapan Augmentasi Data Kelas Minoritas pada Dataset DermaMNIST**?** Bachelor's Thesis. Lampung, Indonesia: Institut Teknologi Sumatera, 2026.

[8] Alexey Dosovitskiy et al. **?**An image is worth 16x16 words: Transformers for image recognition at scale**?** *International Conference on Learning Representations (ICLR)*. 2021.

[9] Fahad Shamshad et al. **?**Transformers in Medical Imaging: A Survey**?** *arXiv preprint arXiv:2201.09873* (2022). arXiv: 2201.09873 [eess.IV].

[10] Aidar Amangeldi et al. **?**CNN and ViT Efficiency Study on Tiny ImageNet and DermaMNIST Datasets**?** *arXiv preprint arXiv:2505.08259* (2025). arXiv: 2505.08259 [cs.CV].

[11] Albert Gu and Tri Dao. **?**Mamba: Linear-Time Sequence Modeling with Selective State Spaces**?** *arXiv preprint arXiv:2312.00752* (2024). arXiv: 2312.00752 [cs.LG].

[12] Yubiao Yue and Zhiming Li. **?**MedMamba: Vision Mamba for Medical Image Classification**?** *arXiv preprint arXiv:2403.03849* (2024). arXiv: 2403.03849 [cs.CV].

[13] Romina Aalishah, Mozhgan Navardi, and Tinoosh Mohsenin. **?**MedMambaLite: Hardware-Aware Mamba for Medical Image Classification**?** *arXiv preprint arXiv:2508.05049* (2025). arXiv: 2508.05049 [cs.CV].

[14] Kumar Abhishek, Aditi Jain, and Ghassan Hamarneh. **?**Investigating the quality of DermaMNIST and Fitzpatrick17k dermatological image datasets**?** *Scientific Data* 12.1 (2025), p. 196.

[15] Jiancheng Yang et al. **?**MedMNIST v2–A large-scale lightweight benchmark for 2D and 3D biomedical image classification**?** *Scientific Data* 10.1 (2023), p. 41.

[16] Matthew Groh et al. **?**Evaluating Deep Neural Networks Trained on Clinical Images in Dermatology with the Fitzpatrick 17k Dataset**?** *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*. 2021, pp. 1820–1828.

[17] Francesco Di Salvo, Sebastian Doerrich, and Christian Ledig. **?**MedMNIST-C: Comprehensive benchmark and improved classifier

robustness by simulating realistic image corruptions**?** *arXiv preprint arXiv:2406.17536* (2024). arXiv: 2406.17536 [eess.IV].

[18] Prannay Khosla et al. **?**Supervised Contrastive Learning**?** *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 33. 2020, pp. 18661–18673.

[19] Mabrouka Salmi et al. **?**Handling imbalanced medical datasets: review of a decade of research**?** *Artificial Intelligence Review* 57.10 (2024), p. 273.

[20] Ze Liu et al. **?**Swin transformer: Hierarchical vision transformer using shifted windows**?** *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 10012–10022.

[21] Sakib Ahammed et al. **?**Adaptive distribution-aware transformer for multi-scale visual representation learning on imbalanced and low-resolution data**?** *Medical Image Analysis* 113 (2026), p. 104162.

[22] Philipp Tschandl, Cliff Rosendahl, and Harald Kittler. **?**The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions**?** *Scientific Data* 5.1 (2018), p. 180161.

[23] Yin Cui et al. **?**Class-Balanced Loss Based on Effective Number of Samples**?** *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2019, pp. 9268–9277.

[24] Yue Liu et al. **?**VMamba: Visual State Space Model**?** *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 37. 2024.

[25] Margherita Grandini, Enrico Bagli, and Giorgio Visani. **?**Metrics for Multi-Class Classification: an Overview**?** *arXiv preprint arXiv:2008.05756* (2020). arXiv: 2008.05756 [stat.ML].

[26] Davide Chicco and Giuseppe Jurman. **?**The Matthews correlation coefficient (MCC) should replace the ROC AUC as the standard metric for assessing binary classification**?** *BioData Mining* 16.1 (2023), p. 4.

[27] Chuan Guo et al. **?**On calibration of modern neural networks**?** *Proceedings of the 34th International Conference on Machine Learning (ICML)*. 2017, pp. 1321–1330.

[28] Xuyin Qi et al. **?**MediAug: Exploring Visual Augmentation in Medical Imaging**?** *arXiv preprint arXiv:2504.18983* (2025). arXiv: 2504.18983 [cs.CV].

[29] Connor Shorten and Taghi M. Khoshgoftaar. **?**A survey on image data augmentation for deep learning**?** *Journal of Big Data* 6.1 (2019), p. 60.

LAMPIRAN

A Dataset

B Hasil Wawancara

C Rincian Kasus Uji